

Grado en Marketing

CURSO 2024/2025

TÉCNICAS ESTADÍSTICAS DE ANÁLISIS DE DATOS CON R

Autor: Ibai Vázquez Souto

Directora: María Jesús Bárcena

Índice

Resumen	4
Introducción	5
1. Análisis de datos de grandes dimensiones	6
1.1. ¿Qué se entiende por Big Data?	6
1.2. Proceso ETL: Extraer, Transformar y Cargar	7
1.3. Importancia del análisis de datos en el ámbito empresarial	8
1.3.1. Netflix: un caso de éxito basado en datos	8
2. Técnicas estadísticas factoriales de análisis de datos multivariantes	10
2.1. Análisis de Componentes Principales	10
2.1.1. Introducción	10
2.1.2. Preparación de los datos	10
2.1.3. Realización del Análisis de Componentes Principales	12
2.1.4. Interpretación de resultados	14
2.1.5. Aplicación a la Encuesta de calidad del Metro Bilbao	16
2.2. Análisis de Correspondencias Simples	25
2.2.1. Introducción	25
2.2.2. Tabla de datos e hipótesis de independencia	25
2.2.3. Obtención de perfiles	27
2.2.4. Descripción de las nubes de perfiles	28
2.2.5. Distancia χ^2 : semejanza entre perfiles	28
2.2.6. Ajuste de las nubes de perfiles	29
2.2.7. Aplicación a la Encuesta de bienestar sobre enseñanza y asistencia sanitaria	32
2.3. Análisis de Correspondencias Múltiples	37
2.3.1. Descripción de los datos	37
2.3.2. Tabla de Burt	38
2.3.3. Distancia χ^2 : semejanza entre perfiles	38
2.3.4. Descripción de las nubes de perfiles fila (individuos) y perfiles columna (modalidades)	39
2.3.5. Valores propios y tasas de inercia proyectadas	39
2.3.6. Plano principal de nube de modalidades activas	41
2.3.7. Interpretación de los dos primeros factores principales	42
2.3.8. Relaciones baricéntricas	43
2.3.9. Variables suplementarias	43
3. Conclusiones	48
Bibliografía	49
Anexo	50

Índice de figuras

1.	Porcentaje de inercia proyectada en cada componente principal.	20
2.	Plano principal de la nube de variables ¹	20
3.	Plano principal de la nube de individuos.	22
4.	Porcentaje de inercia recogida por cada factor principal.	34
5.	Plano principal del AFC	36
6.	Plano principal de la nube de modalidades activas	41
7.	Modalidades suplementarias proyectadas sobre el plano principal del ACM	46

Índice de tablas

1.	Conjunto de datos del grado de satisfacción sobre el Metro Bilbao.	17
2.	Estadísticos descriptivos de las variables.	18
3.	Matriz de correlación.	18
4.	Valores propios y tasas de inercia proyectadas del ACP.	19
5.	Coordenadas, contribuciones y cosenos cuadrados en los dos primeros factores de las variables.	21
6.	Coordenadas, contribuciones y cosenos cuadrados en los dos primeros factores de los individuos.	23
7.	Tabla de contingencia entre la valoración de la Enseñanza y Asistencia Sanitaria. . .	33
8.	Resultado del test Chi-cuadrado.	33
9.	Valores propios y tasas de inercia proyectadas del AFC.	33
10.	Coordenadas, contribuciones, cosenos cuadrados para los dos primeros factores (Dim. 1 y Dim. 2), distancia χ^2 al origen y frecuencias relativas marginales de los perfiles fila.	34
11.	Coordenadas, contribuciones, cosenos cuadrados para los dos primeros factores (Dim. 1 y Dim. 2), distancia χ^2 al origen y frecuencias relativas marginales de los perfiles columna.	35
12.	Coordenadas, cosenos cuadrados y distancia χ^2 al origen de los perfiles columna suplementarios.	35
13.	Valores propios del ACM, tasas de inercia proyectadas originales y corregidas. . . .	40
14.	Coordenadas, contribuciones y cosenos cuadrados para los dos primeros factores de las modalidades activas en el ACM.	42
15.	Coordenadas, Cosenos cuadrados y V-tests para los dos primeros factores de las modalidades suplementarias en el ACM.	45

Resumen

El presente Trabajo Fin de Grado expone un estudio introductorio sobre tres técnicas estadísticas utilizadas en el análisis de datos multivariantes, todas ellas implementadas en RStudio.

En primer lugar, se introducen conceptos básicos relacionados con el análisis de datos de grandes dimensiones en el ámbito empresarial.

A continuación, se describen las técnicas seleccionadas: Análisis de Componentes Principales, Análisis Factorial de Correspondencias Simples y Análisis de Correspondencias Múltiples. Cada una de ellas se presenta desde una perspectiva teórica y se aplica posteriormente a un conjunto de datos reales, con el fin de ilustrar su utilidad en la exploración.

Introducción

El mundo está cambiando rápidamente y, con ello, la forma en que vivimos, trabajamos y nos relacionamos. Este cambio viene impulsado principalmente por la digitalización, proceso mediante el cual se convierte la información y los datos analógicos en formatos digitales, permitiendo su procesamiento y almacenamiento en dispositivos tecnológicos.

Como consecuencia de este proceso, se generan enormes cantidades de datos, comúnmente conocidos como Big Data, cuyo gran tamaño puede dificultar la aplicación de dicha información. Es por ello que, además de equipos de procesamiento masivo, se requiere de herramientas de análisis y modelos estadísticos para interpretar adecuadamente la información y extraer conclusiones relevantes a partir de los datos.

En el ámbito empresarial, trabajar con datos no es un capricho para los más grandes, sino que es una necesidad estratégica para competir en entornos cada vez más orientados a la información. Según un estudio de G2, plataforma de reseñas de software B2B¹ fundada en 2012, alrededor del 40 % de las empresas utilizan análisis de Big Data a nivel mundial (Kumar, 2024).

Los objetivos principales de este Trabajo Fin de Grado son estudiar y aplicar técnicas estadísticas de análisis de datos que actualmente permiten tomar decisiones influyentes a las empresas. Este estudio no busca solo presentar metodologías estadísticas relevantes sino también demostrar su aplicabilidad en entornos reales.

Dado que hay un trasfondo estadístico importante, la metodología y fuentes utilizadas en este trabajo han sido diversas, con el fin de garantizar un análisis fiable. Para aplicar las diferentes técnicas estadísticas se han utilizado conjuntos de datos reales procedentes de diferentes canales de información.

En un contexto empresarial, los datos son el eje central. Es por ello que conseguir conjuntos de datos reales es complejo. Debido a esto, los archivos de datos utilizados en este trabajo son limitados en tamaño. Aún así, permiten ilustrar con precisión la efectividad y aplicabilidad de las técnicas estadísticas.

El Trabajo Fin de Grado se estructura de la siguiente manera. En primer lugar, se presenta una introducción al análisis de datos, donde se explican conceptos fundamentales como Big Data, el proceso ETL (Extract, Transform & Load) y la importancia del análisis de datos en el ámbito empresarial. En la segunda sección se abordan tres técnicas estadísticas concretas, las cuales se explican y aplican de forma integrada, de modo que la teoría y la práctica avanzan de forma conjunta a lo largo del trabajo. Finalmente, se exponen las conclusiones obtenidas y posibles líneas de mejora o desarrollo futuro. En los anexos se incluyen los scripts en R y referencias bibliográficas utilizadas.

¹B2B hace referencia a Business to Business, un modelo de negocio únicamente entre organizaciones.

1 Análisis de datos de grandes dimensiones

1.1 ¿Qué se entiende por Big Data?

No tendría sentido avanzar en este trabajo sin antes detenerse a contextualizar qué se entiende por Big Data. Aunque este concepto parezca novedoso, su origen no es tan reciente como se podría pensar. Para ello, hay que remontarse al año 1990, cuando John Mashey, entonces científico jefe en Silicon Graphics, utilizó por primera vez esta expresión para referirse a los desafíos asociados al manejo y análisis de conjuntos de datos de gran tamaño (Framework, 2024). Aunque en ese momento no existía una definición formal, ya se entendía por Big Data a la complejidad de trabajar con grandes cantidades de datos.

Esta idea se extendió hasta que Doug Laney, un famoso analista, dió una definición que iba a marcar el significado de este concepto, introduciendo el modelo de las 3V's: **Volumen**, **Velocidad** y **Variedad**.

Como se ha destacado al comienzo del trabajo, el **Volumen** es la idea principal de Big Data y hace referencia al gran conjunto de datos que se genera constantemente mediante dispositivos electrónicos. De acuerdo con un estudio realizado por IDC² llamado “Global DataSphere Forecast 2021-2025”, la cifra de datos creados llegará a los 181 zettabytes³ en 2025, que podrían convertirse en 291 zettabytes en 2027 (Hasham, 2023). Para hacernos una idea de la cantidad de datos que se menciona, un cerebro humano es capaz de almacenar aproximadamente $2,5 \times 10^{-6}$ ZB (Jiménez, 2025).

La **Velocidad** hace referencia a la rapidez con la que los datos son creados, accedidos, almacenados y procesados. Esta característica está estrechamente conectada con el análisis en tiempo real, que permite a las empresas tomar decisiones basadas en información muy actualizada. Otro estudio realizado por IDC estima que más de 150 mil millones de dispositivos electrónicos estarán conectados para finales de 2025 y la mayoría de ellos estarán generando datos a tiempo real (Cámara de Tecnologías de Información y Comunicación, 2018).

La característica **Variedad** se refiere a la diversidad de los datos. Esto se debe a que los datos pueden provenir de diferentes fuentes y tener distintos tipos de estructura: estructurados, semiestructurados o no estructurados. Los datos estructurados hacen referencia a la información que ha sido formateada y transformada en un modelo de datos bien definido (Naeem, 2024). Hojas de cálculo Excel y bases de datos relacionales SQL⁴ (Structured Query Language) son el ejemplo perfecto de datos estructurados. Los datos semiestructurados son un tipo de datos que no están organizados en tablas como en una base de datos tradicional, pero tienen cierta estructura y lógica que permite identificarlos de forma sencilla. Entre ellos están archivos CSV (Comma Separated Values) almacenando datos separados por comas, archivos XML (eXtensible Markup Language) representando los datos mediante etiquetas de forma jerárquica y bases de datos no relacionales NoSQL. Por último, los datos no estructurados no están organizados por estructuras ni modelos claros. Tienen una naturaleza muy variada, algunos ejemplos de este tipo son: datos de redes sociales, audios, datos meteorológicos, etc. Son el tipo de

²IDC es una consultora estadounidense, especializada en investigación de mercados y tecnología.

³Un zettabyte (ZB) es una unidad de almacenamiento que equivale a 10^{21} bytes

⁴Se trata de un sistema que organiza la información en tablas de datos relacionadas entre sí, compuestas por filas y columnas.

datos más abundante a día de hoy, representando el 80 % de los datos totales manejados por las empresas (Rodríguez, 2022).

Recientemente, se han añadido dos nuevas características a la definición de Big Data, que dan una compresión más completa del término: **Valor** y **Veracidad**. El valor se refiere a la utilidad real que se obtiene a partir de los datos. Más adelante, en el apartado 1.3, se verá la importancia de esta característica en un contexto empresarial. La veracidad representa la fiabilidad y calidad de los datos, aspectos fundamentales para evitar interpretaciones erróneas.

1.2 Proceso ETL: Extraer, Transformar y Cargar

Big Data no se presenta solo como una oportunidad para las empresas, sino también como un gran reto: ¿cómo organizar, limpiar y hacer accesibles esos datos para su análisis? Aquí es donde el proceso ETL (Extract, Transform & Load) juega su papel.

El proceso ETL consiste en integrar datos de diferentes tipos y fuentes en almacenes de datos, más conocidos como *data warehouses*. Un proceso ETL bien diseñado extrae datos de diferentes fuentes que cumplen con estándares de calidad y asegura que puedan utilizarse conjuntamente por los usuarios finales para tomar decisiones estratégicas.

La primera fase de este proceso es **Extraer** de la fuente de origen los datos que se quieren analizar. Las fuentes y los tipos de datos pueden ser diferentes. En un contexto empresarial, los datos pueden provenir de fuentes internas como sistemas ERP⁵(Enterprise Resource Planning), CRM⁶(Customer Relationship Management), bases de datos internas, etc. Por otro lado, los datos que la empresa extrae de fuentes externas, pueden provenir de APIs⁷(Application Programming Interface), redes sociales, páginas web, etc.

Se extraen todo tipo de datos: estructurados, semiestructurados y no estructurados. En caso de mezclar estos tipos, el proceso ETL puede volverse más complejo.

Una vez los datos han sido extraídos, es hora de transformarlos. Es la fase más importante del proceso, ya que en caso de estar mal ejecutada, puede derivar en un análisis incorrecto. La **Transformación** se encarga de limpiar, homogeneizar y enriquecer la información. La limpieza consiste en corregir errores que puedan interferir en el análisis y eliminar datos repetidos o incompletos. La homogenización o normalización se encarga de unificar la información con el fin de que sea comparable y compatible. En cuanto al enriquecimiento, implica añadir datos de interés relevantes al análisis, con el objetivo de aportar un valor extra.

Por último, el último paso del proceso es la **Carga**. Los datos, una vez extraídos y transformados, se cargan en el sistema de destino, que generalmente es un almacén de datos. Una vez se cargan los datos, están listos para su análisis y toma de decisiones estratégicas. En un contexto empresarial, estos almacenes de datos suelen estar a disposición de la mayoría de departamentos.

Aunque el proceso ETL es ampliamente conocido y utilizado para la integración de datos, en los últimos años ha surgido una variante llamada ELT (Extract, Load & Transform). Este proceso

⁵ERP son paquetes de software orientados a la planificación de recursos que satisfacen la demanda de las necesidades de gestión de la empresa.

⁶CRM se trata de un proceso tecnológico que organiza, automatiza y sincroniza procesos de negocio en una empresa, como pueden ser, ventas, marketing, soporte técnico, etc.

⁷Una API es una interfaz que permite el intercambio de información entre dos componentes de software independientes.

invierte el modelo tradicional, cargando los datos en el destino y posteriormente realizando las transformaciones necesarias.

El auge del proceso ELT viene dado principalmente por el desarrollo de tecnologías de computación en la nube. Plataformas en la nube como Snowflake y Google Big Query, son capaces de almacenar cantidades de datos a gran escala. Además, permiten reducir el tiempo de espera al cargar los datos, facilitan el trabajo con los diferentes tipos de datos y posibilitan transformar los datos varias veces según se requiera. Todas estas soluciones han convertido al proceso ELT como una solución más moderna y práctica para las empresas (Winn, 2024).

1.3 Importancia del análisis de datos en el ámbito empresarial

Las empresas han asumido la necesidad de digitalizarse como una condición esencial para competir en entornos cada vez más analíticos y orientados a la información.

“Los datos son el petróleo del siglo XXI” es una frase que ha sido atribuida a múltiples personas y ha sido ampliamente utilizada en diversos contextos, pero no por ello es menos cierta. Lo que da valor a los datos es que, sin ellos, las empresas se moverían a ciegas en su entorno, guiándose por pura intuición (Seoane, 2025).

Ahora bien, tener datos no es suficiente si no se convierten en valor. Y el valor consiste en utilizarlos para tomar decisiones que realmente impulsen el negocio.

1.3.1 Netflix: un caso de éxito basado en datos

“En Netflix usamos datos para tomar prácticamente todas las decisiones.” Así es como Reed Hastings, cofundador y CEO de Netflix, resume a la perfección el camino que ha seguido la empresa desde sus inicios (Jangam, 2023).

A principios del siglo XXI, Netflix era una empresa de alquiler de DVDs por correo postal. Sin embargo, vio una oportunidad en la digitalización y transformó la forma en la que se consumían los contenidos audiovisuales. En 2007, Netflix introdujo su servicio de streaming, que permitía a los clientes ver películas y series de televisión al instante, sin necesidad de esperar un soporte físico.

El servicio de streaming no se presentaba solo como una oportunidad, sino también como un desafío importante: contar con un catálogo de contenidos audiovisuales que satisficiera a gran parte de clientes, pero con un presupuesto limitado. Aquí es donde Netflix utilizó Big Data con el objetivo de comprender los gustos y comportamientos de los usuarios. De esta manera, Netflix empezó a tomar decisiones de compra de licencias en base a estos datos.

Otro de los pilares fundamentales de Netflix ha sido el desarrollo de técnicas estadísticas para ofrecer recomendaciones personalizadas. El sistema, con los datos que recoge continuamente de los usuarios, intenta predecir qué títulos son más interesantes para cada cliente. Su objetivo es personalizar lo máximo posible la experiencia del usuario y ayudarle a encontrar fácilmente contenido relevante según sus intereses.

Uno de los casos más conocidos que refleja como Netflix usa Big Data es el lanzamiento de la serie House of Cards (2013). Producida al 100 % por Netflix, esta serie, marcaría un antes y un después en la toma de decisiones de la empresa (Rodríguez, 2018).

Aunque la versión original fue producida por la BBC en 1990, la decisión de producir y lanzar una versión americana de esta serie fue guiada por una enorme cantidad de datos. En ellos, Netflix

observó patrones de comportamiento entre los usuarios, como la preferencia por las obras del director David Fincher y del actor principal Kevin Spacey y el alto interés por contenidos relacionados con la política.

Además, la empresa identificó que las series dramáticas se tendían a ver de forma continuada, es decir, varios episodios seguidos. Esto fue clave para que la empresa optara por lanzar de forma simultánea la primera temporada entera (13 capítulos), rompiendo con lo convencional que era publicar un capítulo por semana.

Por otro lado, Netflix adaptó estrategias de marketing basadas en datos. Antes del lanzamiento de la serie, Netflix probó distintas portadas y trailers como avances o anuncios promocionales dentro de la plataforma para diferentes segmentos de usuarios, con el fin de ver cuáles generaban más interés.

La identificación de patrones en los datos de los usuarios dieron lugar a una de las series más famosas de ese momento y consolidó a Netflix no solo como una gran empresa distribuidora, sino como productora de cine.

2 Técnicas estadísticas factoriales de análisis de datos multivariantes

En este trabajo se presentan tres técnicas factoriales de análisis de datos multivariantes: Análisis de Componentes Principales, Análisis de Correspondencias Simples y Análisis de Correspondencias Múltiples.

Antes de proceder con el estudio de estas técnicas, se debe mencionar los recursos y bibliografía utilizados. Se fundamenta en dos libros. Por una parte, “Estadística Exploratoria Multivariante: Teoría y Aplicaciones en Investigación de Mercados” (Fernández & Modroño, s.f.). Por otro lado, “Análisis de datos con R” (Husson et al., 2013). La implementación y metodología del trabajo se ha realizado haciendo uso del lenguaje de programación R (R Team, 2025) empleando el software RStudio (Posit Software, 2025), siguiendo las indicaciones que se usan en el libro de Husson. En el anexo se podrá encontrar el código y paquetes de RStudio utilizados para el estudio y diseño del trabajo.

2.1 Análisis de Componentes Principales

2.1.1 Introducción

El Análisis de Componentes Principales (ACP) es una técnica estadística de reducción de dimensionalidad aplicable a una matriz de datos de variables cuantitativas. Permite transformar un conjunto de variables correlacionadas en un nuevo conjunto de variables no correlacionadas llamadas componentes principales. Su principal objetivo es resumir la información contenida en los datos con el menor número posible de variables, minimizando la pérdida de información y encontrando un espacio de menor dimensión donde se refleja la información más relevante.

El ACP se basa en la descomposición espectral de la matriz de covarianzas o de correlación de los datos, extrayendo direcciones ortogonales en las que la varianza es máxima. Estas direcciones corresponden a los vectores propios de la matriz de covarianzas, mientras que sus valores propios indican la cantidad de varianza explicada por cada componente.

Las principales ventajas del ACP incluyen la reducción del ruido en los datos y la posibilidad de visualizar la estructura de los mismos en menos dimensiones. Sin embargo, su principal limitación radica en que las nuevas variables no siempre tienen una interpretación directa en el contexto original del problema.

2.1.2 Preparación de los datos

En un ACP se analiza un conjunto de datos compuesto por n observaciones de p variables cuantitativas. Representamos los datos en una matriz X de dimensiones $n \times p$:

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

donde cada fila representa un individuo i , $i = 1, \dots, n$ y cada columna una variable X_j , $j = 1, \dots, p$.

Si representamos las filas de X , obtenemos la nube de puntos del individuo, N_I , formada por n puntos de $\mathbb{R}^p$. Dos individuos estarán más próximos en esta nube cuanto más parecidos sean los valores que toman de las variables estudiadas.

En cambio, si representamos las columnas de X , obtenemos la nube de puntos de variable N_J , formada por p puntos de $\mathbb{R}^n$. La proximidad entre variables será interpretada en términos de correlación.

Estadísticos descriptivos multidimensionales

Antes de aplicar el ACP, es recomendable calcular los principales estadísticos descriptivos para comprender la estructura de los datos:

- **Vector de medias**, compuesto por la media de cada variable X_j :

$$\bar{\mathbf{x}}_j = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_{ij}, \quad \forall j = 1, \dots, p$$

Un individuo medio, con valores $(\bar{x}_1, \dots, \bar{x}_p)$, estará situado en el centro de gravedad de N_I .

- **Varianza y desviación típica** de cada variable:

$$s_j^2 = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_{ij} - \bar{\mathbf{x}}_j)^2, \quad s_j = \sqrt{s_j^2}, \quad \forall j = 1, \dots, p$$

Indican la dispersión de cada variable X_j .

- **Mínimo y máximo** de cada variable:

$$x_j^{\min} = \min(x_{1j}, x_{2j}, \dots, x_{nj}), \quad x_j^{\max} = \max(x_{1j}, x_{2j}, \dots, x_{nj})$$

Estos valores ayudan a identificar rangos y posibles valores atípicos.

Estandarización o tipificación de variables

Mediante la estandarización o tipificación se consigue que las variables tengan la misma escala. De no ser así, las variables con mayor dispersión o varianza influirán más en los resultados del ACP. La estandarización se realiza restando la media y dividiendo entre la desviación estándar de cada variable X_j :

$$z_{ij} = \frac{\mathbf{x}_{ij} - \bar{\mathbf{x}}_j}{s_j}, \quad \forall i = 1, \dots, n, \quad \forall j = 1, \dots, p$$

Esto asegura que cada variable tenga **media 0 y varianza 1**, eliminando el efecto de las unidades de medida en el análisis.

Matriz de covarianzas y matriz de correlación

Antes de proceder con el Análisis de Componentes Principales, es fundamental examinar la estructura de los datos a través de medidas estadísticas que reflejen la relación lineal entre las variables. Dos herramientas clave en este análisis son la matriz de covarianzas y la matriz de correlación, las cuales nos permiten identificar patrones de variabilidad y relación lineal en los datos. A continuación, se presentan sus definiciones y propiedades.

- **Matriz de covarianzas:** compuesta por las varianzas en la diagonal principal y fuera de la diagonal las covarianzas.

$$S = \begin{bmatrix} s_1^2 & s_{12} & \dots & s_{1p} \\ s_{21} & s_2^2 & \dots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \dots & s_p^2 \end{bmatrix}$$

Donde s_{jk} es la covarianza entre las variables X_j y X_k , $\forall j = 1, \dots, p$, $\forall k = 1, \dots, p$.

Las covarianzas muestran las relaciones lineales entre las p variables estudiadas ($X_1, X_2, \dots, X_p$).

- **Matriz de correlación**

$$R = \begin{bmatrix} 1 & r_{12} & \dots & r_{1p} \\ r_{21} & 1 & \dots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \dots & 1 \end{bmatrix} \quad \text{donde} \quad r_{jk} = \frac{s_{jk}}{s_j \cdot s_k}$$

Al igual que la covarianza s_{jk} , si r_{jk} es positivo hay relación lineal directa entre las variables X_j y X_k . En cambio, si r_{jk} es negativo, hay relación lineal inversa entre las variables X_j y X_k . El valor absoluto de r_{jk} está acotado entre 0 y 1 ($0 \leq |r_{jk}| \leq 1$), y la relación lineal es más fuerte cuanto mayor sea dicho valor absoluto.

La matriz de correlación es igual a la matriz de covarianzas de las variables previamente tipificadas.

2.1.3 Realización del Análisis de Componentes Principales

En un ACP se trabaja con la matriz de datos X centrados o tipificados. Por tanto, en el origen o centro de gravedad de la nube de puntos individuo, N_I , se sitúa un individuo medio. Por este punto pasarán todos los ejes principales.

En un ACP, se diagonaliza la matriz de covarianzas o la matriz de correlación, depende de la escala de las variables originales.

- Si las variables tienen escalas similares, el ACP se basa en los vectores y valores propios de la matriz de covarianzas (S).

- Si las variables están en escalas muy diferentes, se tipifican (media 0 y varianza 1) y se diagonaliza la matriz de correlación (R) para que todas las variables tengan la misma contribución en el análisis.

Habitualmente, el ACP se realizará utilizando la matriz de correlación (se dice entonces que se realiza un ACP normado).

Tanto S como R son matrices simétricas y, por tanto, diagonalizables: tienen valores propios reales (siempre mayores o iguales que 0) y direcciones propias ortogonales entre sí.

Cuando trabajamos con datos reales, normalmente hay p valores propios diferentes que se ordenan de mayor a menor:

$$\lambda_1 > \lambda_2 > \lambda_3 > \dots > \lambda_k > \dots > \lambda_p$$

En un ACP normado, denotamos $\vec{v}_k$ a un vector unitario asociado a λ_k :

$$R \cdot \vec{v}_k = \lambda_k \cdot \vec{v}_k$$

En la nube de puntos individuo, N_I , la recta que pasa por el centro de gravedad y tiene como vector director unitario $\vec{v}_1$, será el primer componente principal, F_1 . Las coordenadas o proyecciones de los n individuos sobre esta recta serán la representación más fiel a la nube N_I original que pueda obtenerse en una sola dimensión.

En general, la dirección propia asociada a λ_k proporciona el k -ésimo componente principal ($\forall k = 1, \dots, p$).

El valor propio asociado a cada dirección, λ_k , mide la cantidad de información recogida en cada eje principal. Coincide con la varianza de las proyecciones sobre el k -ésimo eje principal.

Los ejes factoriales son perpendiculares entre sí y, por lo tanto, con dos ejes factoriales se forman planos factoriales. El plano principal estará formado por los dos primeros ejes y la nube proyectada sobre este plano será la representación más fiel en dos dimensiones de la nube original.

Selección del número de componentes principales

En un ACP, seleccionando los primeros componentes principales se consigue resumir la información más relevante contenida en los datos. Es importante determinar cuántos ejes principales retener e interpretar. Para ello, se utiliza el porcentaje de varianza o inercia recogida en cada eje factorial.

Cada componente principal captura una fracción de la varianza total de los datos. La proporción de varianza proyectada en el k -ésimo componente se define como:

$$\lambda_k^* = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j}$$

donde:

- λ_k es el valor propio asociado a la k -ésima componente.
- $\sum_{j=1}^p \lambda_j$ es la suma total de los valores propios. Si el ACP es normado, esta suma es igual a p .

La **proporción de varianza proyectada acumulada** hasta el m -ésimo componente se obtiene sumando las proporciones de los primeros m componentes:

$$V_m = \sum_{k=1}^m \lambda_k^*$$

En un ACP normado, un criterio habitual es conservar los componentes cuyos valores propios sean mayores que 1, siguiendo la regla de Kaiser. Esta regla se basa en la idea de que un componente con un valor propio superior a 1 explica más variabilidad que una variable original en promedio, por lo que se considera relevante en la estructura de los datos.

El porcentaje de varianza explicada mide qué parte de la información original se conserva con los componentes seleccionados. En general, se busca retener suficientes factores para alcanzar un porcentaje acumulado significativo, alrededor del 80 %, asegurando así que la reducción de dimensiones no implique una pérdida excesiva de información.

Para decidir cuántos ejes principales interpretar, se suele utilizar un diagrama de barras, que representa los valores propios en orden descendente. Este gráfico permite identificar visualmente un punto de inflexión o “codo”, donde la disminución en los valores propios se vuelve menos pronunciada.

2.1.4 Interpretación de resultados

Proyecciones o coordenadas de los individuos

La k -ésima componente principal de la nube de puntos individuo, F_k , será el vector compuesto por las proyecciones de todos los individuos sobre el k -ésimo eje principal:

$$F_k = (F_k(1), \dots, F_k(i), \dots, F_k(n))^t$$

La proyección o coordenada de cada individuo i sobre el k -ésimo eje principal se calcula multiplicando la fila i -ésima de la matriz de datos centrados (o tipificados) por el vector propio $\vec{v}_k$. Se representa de la siguiente manera:

$$F_k(i) = \vec{x}(i)^t \cdot \vec{v}_k = (x_{i1}, \dots, x_{ij}, \dots, x_{ip}) \cdot \vec{v}_k \quad (1)$$

Los individuos se proyectan en los ejes principales según sus coordenadas $F_k(i)$. Si $F_k(i) > 0$, el individuo i se proyecta en el lado positivo del eje k . Si $F_k(i) < 0$, el individuo i se proyecta en el lado negativo del eje k .

Matricialmente, ocurre que:

$$F_k = X \cdot \vec{v}_k = v_{1k}X_1 + \dots + v_{pk}X_p, \quad \forall k = 1, \dots, p$$

donde $(X_1, \dots, X_p)$ son las variables estudiadas, es decir, las columnas de la matriz de datos X y $\vec{v}_k = (v_{1k}, \dots, v_{pk})^t$.

Resultando que cada componente principal F_k está relacionado con las p variables originales; es una combinación lineal de ellas diseñada para capturar la mayor variabilidad posible en los datos.

Proyecciones o coordenadas de las variables

La coordenada, proyección o carga factorial de la variable X_j sobre el k -ésimo eje principal, l_{jk} , se calcula como:

$$l_{jk} = v_{jk} \sqrt{\lambda_k}, \quad \forall j = 1, \dots, p \quad (2)$$

donde v_{jk} es el componente j -ésimo del vector propio unitario $\vec{v}_k$.

En un ACP normado, las coordenadas o proyecciones de las variables son equivalentes a los coeficientes de correlación entre cada variable original y los componentes principales.

$$l_{jk} = \text{corr}(X_j, F_k)$$

Las variables se proyectan en los ejes principales según sus cargas factoriales l_{ik} . Si $l_{ik} > 0$, la variable j contribuye positivamente a la componente principal k ($\text{corr}(X_j, F_k) > 0$), y se proyecta en el lado positivo del eje. Si $l_{ik} < 0$, la variable j contribuye negativamente ($\text{corr}(X_j, F_k) < 0$), y se proyecta en el lado negativo del eje.

Relaciones de transición

En el Análisis de Componentes Principales (ACP), la interpretación de las relaciones entre las variables, los individuos y las componentes principales es fundamental para comprender la estructura de los datos. Estas relaciones se pueden analizar a través de las cargas factoriales y las coordenadas de los individuos, las cuales permiten visualizar cómo las variables y los individuos se proyectan en el espacio reducido de las componentes principales. A continuación, se detallan estas relaciones y su interpretación.

Los resultados obtenidos al estudiar ambas nubes (individuos, N_I , y variables, N_J) están relacionadas mediante las llamadas relaciones de transición de la siguiente manera, uniendo las expresiones (1) y (2):

$$F_k(i) = \frac{1}{\sqrt{\lambda_k}} [x_{i1} \cdot l_{1k} + \dots + x_{ij} \cdot l_{jk} + \dots + x_{ip} \cdot l_{pk}]$$

Se puede observar que la proyección de un individuo sobre el k -ésimo eje, $F_k(i)$, es una combinación lineal de las proyecciones de las p variables sobre el eje $(l_{1k}, \dots, l_{pk})$. Los coeficientes de dicha combinación lineal, $(x_{i1}, \dots, x_{ip})$, corresponden a los valores de las variables previamente centradas y reescaladas para cada individuo. Estos coeficientes adoptan valores positivos cuando el individuo presenta valores superiores a la media de la variable correspondiente, y negativos en caso contrario.

En consecuencia, si se representan conjuntamente en un mismo gráfico las proyecciones de los individuos y de las variables, cada individuo tenderá a proyectarse hacia el mismo lado que aquellas variables respecto de las cuales toma valores superiores a la media y, viceversa, al lado opuesto de las variables en las que toma un valor menor que la media.

2.1.5 Aplicación a la Encuesta de calidad del Metro Bilbao

Metro Bilbao realiza periódicamente encuestas en todas las estaciones para conocer el índice general de satisfacción de las personas usuarias y la valoración pormenorizada de los principales indicadores. Se sirve, año a año, de la opinión de 1.100 viajeros habituales (433 hombres y 667 mujeres) para introducir las mejoras oportunas en el servicio. Son los clientes que conforman el llamado panel de Metro Bilbao, un sondeo a través del que la compañía comprueba de forma periódica las necesidades que observan los pasajeros.

Descripción de los datos

La tabla de datos que se analiza contiene un extracto de los datos publicados en la página web oficial del Metro Bilbao. Estos datos provienen de encuestas anuales, desde el 2012 hasta la actualidad, realizadas a los usuarios del servicio con el objetivo de evaluar distintos aspectos de la experiencia de viaje y mejorar la calidad del transporte.

En la encuesta, los pasajeros valoran 15 atributos del servicio utilizando una escala ordinal de satisfacción del 1 al 10.

En la tabla siguiente aparecen los valores x_{ij} , puntuaciones medias asignadas por los encuestados que responden en el año i ($i=2012, \dots, 2024$) para cada variable j ($j = 1, \dots, 15$). Estas variables, en columnas, son respectivamente: *Puntualidad*, *Limpieza*, *Rapidez*, *Seguridad*, *Comodidad*, *Frecuencia*, *Información*, *Precios*, *Señalización de estaciones*, *Atención clientes*, *Ascensores*, *Escaleras mecánicas*, *Canceladoras*, *Máquinas expendedoras*, *Metro en general*.

La tabla muestra los datos correspondientes a los años 2012 a 2024. Adicionalmente, se han incorporado tres filas al final que presentan, para cada variable: el valor medio, mínimo y máximo, con el fin de facilitar la interpretación de los resultados y el análisis.

Tabla 1: Conjunto de datos del grado de satisfacción sobre el Metro Bilbao.

	Punt.	Limp.	Rap.	Seg.	Com.	Frec.	Inf.	Prec.	S. E.	A. C.	Asc.	E. M.	Canc.	M. E.	M. G.
2012	7.90	8.40	8.10	7.70	7.70	7.60	6.90	5.6	7.80	7.70	7.6	7.70	8.20	7.70	7.90
2013	7.90	8.40	8.10	7.70	7.70	7.60	6.90	5.6	7.80	7.70	7.6	7.70	8.20	7.70	7.90
2014	8.10	8.60	8.20	8.00	8.00	7.70	7.10	5.7	7.90	7.90	7.5	7.90	7.80	7.80	8.10
2015	8.20	8.60	8.20	8.00	8.00	7.80	7.20	6.0	7.90	8.10	7.7	7.90	7.90	7.90	8.20
2016	8.10	8.60	8.10	7.90	7.80	7.80	7.20	6.1	7.80	7.80	7.4	7.70	7.90	8.00	8.10
2017	8.10	8.60	8.20	7.80	7.90	7.80	7.20	6.0	7.80	7.80	7.6	7.90	7.70	8.00	8.10
2018	8.20	8.60	8.20	7.90	7.90	7.70	7.50	5.9	8.10	8.00	7.6	7.90	8.00	8.10	8.10
2019	8.10	8.60	8.20	7.70	7.90	7.60	7.30	6.3	8.00	8.00	7.6	8.00	7.80	7.80	8.00
2020	8.40	8.60	8.40	7.90	8.10	8.00	7.60	6.5	8.10	8.20	7.8	8.10	7.90	8.00	8.30
2021	8.20	8.40	8.30	7.60	7.80	7.80	7.60	6.8	8.20	8.00	7.6	7.80	8.00	7.90	8.00
2022	8.20	8.20	8.30	7.60	7.70	7.70	7.40	7.3	8.00	7.70	7.6	7.70	7.90	7.90	8.00
2023	8.00	8.30	8.20	7.60	7.60	7.70	7.50	7.6	8.10	7.90	7.5	7.80	8.00	7.90	8.00
2024	8.30	8.50	8.40	7.90	7.70	8.00	7.60	7.8	8.30	8.10	7.7	7.80	8.20	8.10	8.20
Med.	8.13	8.49	8.22	7.79	7.83	7.75	7.31	6.4	7.98	7.92	7.6	7.84	7.96	7.91	8.07
Mín.	7.90	8.20	8.10	7.60	7.60	7.60	6.90	5.6	7.80	7.70	7.4	7.70	7.70	7.70	7.90
Máx.	8.40	8.60	8.40	8.00	8.10	8.00	7.60	7.8	8.30	8.20	7.8	8.10	8.20	8.10	8.30

Elección del análisis

Se analizan los factores clave que influyen en la percepción de la calidad del servicio de Metro Bilbao desde el año 2012 al año 2024.

En este contexto, las variables activas en el análisis corresponden a los factores clave que definen la percepción del servicio de transporte en tren. Son las ocho primeras variables de la tabla: *Puntualidad*, *Limpieza*, *Rapidez*, *Seguridad*, *Comodidad*, *Frecuencia*, *Información* y *Precios*.

Por otro lado, se toman como variables suplementarias las siete últimas variables de la Tabla 1: *Señalización de estaciones*, *Atención clientes*, *Ascensores*, *Escaleras mecánicas*, *Canceladoras*, *Máquinas expendedoras* y *Metro en general*. Estas variables no definen el servicio de transporte, pero si lo complementan. Aunque no se integran en los componentes principales, estas variables suplementarias sirven como indicadores adicionales para interpretar los resultados del análisis y contextualizar las conclusiones.

El objetivo final es obtener una visión general sobre las relaciones entre las variables de satisfacción del servicio y así poder identificar factores clave que expliquen la variabilidad en las opiniones de los usuarios de Metro Bilbao. Esto permitirá, por ejemplo, responder preguntas como: ¿cuáles son los aspectos del servicio que más contribuyen a la satisfacción general de los usuarios?, ¿qué relaciones hay entre los distintos aspectos que afectan al grado de satisfacción?

Puesta en práctica

Antes de realizar el ACP es recomendable calcular los principales estadísticos descriptivos para comprender la estructura de los datos.

Tabla 2: Estadísticos descriptivos de las variables.

	Recuento	Media	Desv. Típ.	CV	Mín	Máx
Puntualidad	13	8.13	0.14	0.02	7.9	8.4
Limpieza	13	8.49	0.14	0.02	8.2	8.6
Rapidez	13	8.22	0.10	0.01	8.1	8.4
Seguridad	13	7.79	0.15	0.02	7.6	8.0
Comodidad	13	7.83	0.15	0.02	7.6	8.1
Frecuencia	13	7.75	0.13	0.02	7.6	8.0
Información	13	7.31	0.25	0.03	6.9	7.6
Precios	13	6.40	0.75	0.12	5.6	7.8
Señalización._estaciones	13	7.98	0.17	0.02	7.8	8.3
Atención_clientes	13	7.92	0.17	0.02	7.7	8.2
Ascensores	13	7.60	0.10	0.01	7.4	7.8
Escaleras_mecánicas	13	7.84	0.13	0.02	7.7	8.1
Canceladoras	13	7.96	0.16	0.02	7.7	8.2
Máquinas_expendedoras	13	7.91	0.13	0.02	7.7	8.1
Metro_en_general	13	8.07	0.12	0.01	7.9	8.3

Las variables analizadas presentan distintos grados de variabilidad. Entre ellas, la variable *Precios* destaca por su mayor dispersión, con una desviación típica de 0.75 y coeficiente de variación de 0.12, lo que refleja opiniones más diversas entre los usuarios. En contraste, las variables *Rapidez* y *Ascensores* muestran una notable homogeneidad en las valoraciones, con una desviación típica de 0.10.

La variable *Metro en general* es una variable suplementaria en el análisis, lo que significa que no participa activamente en la construcción de los componentes principales, pero resulta clave para interpretar los resultados. Su alta y estable puntuación respalda la idea de que el servicio mantiene un buen nivel de satisfacción.

Matriz de correlación

Antes de examinar los resultados del ACP, es útil analizar las relaciones lineales entre las variables activas observando la matriz de correlación.

Tabla 3: Matriz de correlación.

	Punt.	Limp.	Rap.	Seg.	Com.	Frec.	Inf.	Prec.
Punt.	1.00	0.49	0.90	0.56	0.69	0.87	0.83	0.59
Limp.	0.49	1.00	0.20	0.83	0.81	0.45	0.23	-0.13
Rap.	0.90	0.20	1.00	0.30	0.45	0.83	0.85	0.76
Seg.	0.56	0.83	0.30	1.00	0.76	0.58	0.19	-0.02
Com.	0.69	0.81	0.45	0.76	1.00	0.53	0.33	-0.02
Frec.	0.87	0.45	0.83	0.58	0.53	1.00	0.72	0.61
Inf.	0.83	0.23	0.85	0.19	0.33	0.72	1.00	0.79
Prec.	0.59	-0.13	0.76	-0.02	-0.02	0.61	0.79	1.00

La matriz revela relaciones lineales interesantes entre las distintas variables de evaluación del Metro Bilbao. Se observa una fuerte correlación positiva entre *Puntualidad* (Punt.), *Rapidez* (Rap.) y *Frecuencia* (Frec.), con valores muy próximos a uno, lo que sugiere que los usuarios perciben estos aspectos como estrechamente vinculados. Esta relación podría indicar que, cuando el servicio es puntual, tiende a ser también rápido y frecuente, formando así un bloque coherente de calidad

operativa.

Por otro lado, *Limpieza* (Limp.) muestra un comportamiento diferenciado, correlacionándose fuertemente con *Seguridad* (Seg.) y *Comodidad* (Com.), pero presentando valores bajos con otras variables como *Rapidez* o *Información* (Inf.). Esto apunta a que la limpieza pertenece a una dimensión distinta, posiblemente relacionada con la experiencia física en las instalaciones, mientras que aspectos como la rapidez o la información estarían más asociados a la eficiencia del servicio.

La variable satisfacción con *Precios* (Prec.) destaca por sus bajas correlaciones con *Limpieza*, *Seguridad* y *Comodidad*, lo que podría reflejar una percepción de los usuarios donde una mayor satisfacción con estos aspectos no compensa el descontento con las tarifas. Sin embargo, su correlación positiva con *Rapidez* e *Información* introduce un matiz interesante, sugiriendo que, en cierta medida, los usuarios podrían asociar un servicio rápido y bien informado con una mejor relación calidad-precio.

Valores propios y tasas de inercia proyectadas

Tabla 4: Valores propios y tasas de inercia proyectadas del ACP.

	Valores propios	Inercia proyectada (%)	Inercia acumulada (%)
comp 1	3.97	49.59	49.59
comp 2	2.95	36.84	86.43
comp 3	0.47	5.91	92.35
comp 4	0.28	3.46	95.80
comp 5	0.16	1.96	97.76
comp 6	0.09	1.14	98.90
comp 7	0.05	0.67	99.57
comp 8	0.03	0.43	100.00

Los resultados del análisis de componentes principales revelan una estructura clara en la percepción de los usuarios sobre el servicio de Metro Bilbao. El primer componente principal representa el 49.59 % de la variabilidad total, lo que significa que recoge casi la mitad de la información de los datos. Esto indica que hay un factor clave que resume en gran parte las valoraciones de los usuarios.

El segundo componente principal explica un 36.84 % adicional de la varianza, elevando la varianza acumulada al 86.43 %. Esto indica que los dos primeros componentes son suficientes para representar la mayor parte de la información contenida en los datos. Además, la marcada diferencia entre estos dos componentes principales y los siguientes (a partir del tercer componente, cada uno con menos del 6 % de varianza explicada) refuerza la importancia de centrar el análisis en estas dos primeras dimensiones.

Para visualizarlo de manera más clara, a continuación se representan las tasas de inercia proyectadas sobre cada factor o componente principal mediante un gráfico de codo, que permite identificar el punto óptimo de corte en la selección de los dos primeros componentes principales.




Figura 1: Porcentaje de inercia proyectada en cada componente principal.




Figura 2: Plano principal de la nube de variables⁸

Descripción del plano principal de la nube de variables

De acuerdo con la Figura 1, las dos primeras dimensiones o componentes principales explican la mayor parte de la información total del conjunto de datos. Estos componentes forman el plano que aparece representado en la Figura 2, donde se muestra el plano principal de la nube de variables. En trazo continuo aparecen las proyecciones de las variables activas y en trazo discontinuo las suplementarias.

Cada componente principal se interpreta en función de las coordenadas o proyecciones de las variables activas que más contribuyen a su formación (contribución alta) y que estén bien representadas en él (coseno cuadrado alto). Estos resultados se presentan en la Tabla 5, que muestra, en orden, las coordenadas de las variables, su contribución y calidad de representación (coseno cuadrado) en las dos primeras dimensiones o factores principales.

Tabla 5: Coordenadas, contribuciones y cosenos cuadrados en los dos primeros factores de las variables.

	Dim.1	Dim.2	Dim.1	Dim.2	Dim.1	Dim.2
Puntualidad	0.97	0.06	23.68	0.14	0.94	0.00
Limpieza	0.30	0.88	2.26	26.42	0.09	0.78
Rapidez	0.90	-0.31	20.43	3.18	0.81	0.09
Seguridad	0.39	0.81	3.81	22.15	0.15	0.65
Comodidad	0.45	0.79	5.22	21.06	0.21	0.62
Frecuencia	0.90	0.04	20.34	0.05	0.81	0.00
Información	0.83	-0.41	17.29	5.69	0.69	0.17
Precios	0.53	-0.79	6.97	21.31	0.28	0.63

Las coordenadas de las variables muestran cómo se relaciona cada variable con las dos dimensiones o componentes principales extraídas. La primera componente (Dim.1) presenta correlaciones particularmente altas con las variables *Puntualidad* (0.97), *Rapidez* (0.90), *Frecuencia* (0.90) e *Información* (0.83), lo que sugiere que esta dimensión podría interpretarse como una mayor satisfacción con la eficiencia operacional del servicio. Este componente tiene correlaciones positivas con todas las variables, es decir, todas las variables activas aparecen proyectadas en el mismo lado del eje, lo que se denomina “eje de talla”.

Atendiendo a las variables suplementarias, *Máquinas Expendedoras*, *Señalización de estaciones* y *Atención al cliente* refuerzan la interpretación del primer factor (Dim. 1) como eficiencia operacional, ya que una señalización clara y un servicio al cliente ágil contribuyen directamente a la puntualidad, rapidez y acceso a la información, consolidando así la percepción de un servicio eficiente y bien coordinado.

Por su parte, la segunda componente (Dim.2) tiene una fuerte correlación positiva con *Limpieza* (0.88), *Seguridad* (0.81), *Comodidad* (0.79) y, en sentido negativo, con *Precios* (-0.79) y la variable suplementaria *Señalización*, lo que indica que esta dimensión se relaciona con la satisfacción asociada a la calidad percibida y al coste del servicio.

Los cosenos cuadrados (últimas dos columnas de la Tabla 5) reflejan el grado de representación de cada variable en el plano principal. Los valores cercanos a uno indican una representación casi

perfecta. En este análisis, variables como *Puntualidad* (0.94 en Dim.1), *Rapidez* (0.81 en Dim.1) y *Limpieza* (0.78 en Dim.2) muestran una excelente representación en sus respectivas dimensiones dominantes. La suma de los cosenos cuadrados para cada variable en ambas dimensiones revela que todas las variables están bien representadas en el plano principal (todas ellas están cerca del círculo de radio uno en el gráfico de la Figura 2).

Las contribuciones muestran qué variables tienen mayor protagonismo en la formación de cada componente. Para la Dim.1 (tercera columna de la Tabla 5), las mayores contribuciones provienen de *Puntualidad* (23.68 %), *Rapidez* (20.43 %) *Frecuencia* (20.34 %) e *Información de trenes*, lo que refuerza su papel central en la definición de la dimensión de eficiencia operacional. En la Dim.2, las variables *Limpieza* (26.42 %), *Seguridad* (22.15 %), *Comodidad* (21.06 %) y *Precios* (21.31 %) destacan como los factores determinantes de la dimensión relacionada con la calidad percibida.

Como se ha analizado anteriormente, la primera componente (Dim.1) agrupa aspectos funcionales y operativos como puntualidad, rapidez y frecuencia, mientras que la segunda componente (Dim.2) engloba atributos más relacionados con la experiencia del usuario, como limpieza, seguridad y comodidad, junto con la variable económica de precios (que aparece con signo negativo, sugiriendo una relación inversa con la satisfacción). Esta estructura factorial sugiere que los usuarios distinguen claramente entre dos aspectos clave al evaluar el servicio: eficiencia funcional y calidad percibida en relación al coste.

Descripción del plano principal de la nube de individuos




Figura 3: Plano principal de la nube de individuos.

Tabla 6: Coordenadas, contribuciones y cosenos cuadrados en los dos primeros factores de los individuos.

	Dim.1	Dim.2	Dim.1	Dim.2	Dim.1	Dim.2
2012	-3.36	-0.02	21.94	0.00	0.97	0.00
2013	-3.36	-0.02	21.94	0.00	0.97	0.00
2014	-0.35	2.31	0.23	13.99	0.02	0.88
2015	0.64	2.07	0.80	11.16	0.08	0.84
2016	-0.59	1.19	0.68	3.72	0.10	0.42
2017	-0.14	1.07	0.04	2.97	0.01	0.70
2018	0.48	1.17	0.44	3.57	0.07	0.45
2019	-0.70	0.42	0.95	0.45	0.17	0.06
2020	3.88	1.06	29.17	2.96	0.88	0.07
2021	1.00	-1.74	1.95	7.94	0.20	0.60
2022	0.10	-2.98	0.02	23.10	0.00	0.87
2023	-0.83	-3.07	1.35	24.58	0.06	0.86
2024	3.25	-1.46	20.49	5.54	0.70	0.14

En el plano principal de la Figura 3 aparecen proyectados los 13 individuos de nuestro análisis, es decir, los años desde 2012 hasta 2024. En el origen del gráfico se sitúa un “año medio” (cuyo valor de todas las variables activas fuese igual a la media del conjunto). Las coordenadas o proyecciones de cada año aparecen en las dos primeras columnas de la Tabla 6.

En cada eje se interpretan los individuos que más contribuyen a su formación (contribución alta) y que están bien representados (coseno cuadrado alto). Estos valores también aparecen en la Tabla 6.

La nube de individuos del ACP revela la evolución del grado de satisfacción con el servicio del Metro Bilbao entre 2012 y 2024, proyectada sobre el espacio bidimensional formado por los dos componentes principales anteriormente definidos (eficiencia funcional para la Dim. 1 y calidad percibida en relación al coste para la Dim. 2).

Los años 2020 y 2024 se posicionan hacia la derecha del gráfico, lo que indica una mejora percibida en la eficiencia operativa, atribuible probablemente a factores como una mayor satisfacción que la media en *Puntualidad* y *Rapidez*. En contraste, los años 2012 y 2013 se encuentran hacia la izquierda del gráfico, lo que sugiere una valoración menor que la media en relación con la eficiencia funcional.

En relación al grado de satisfacción con la calidad y el coste del servicio (Dim. 2), se observa que los años 2014 y 2015 se sitúan en la parte superior del gráfico, indicando una valoración mayor que la media en aspectos como la *Limpieza*, *Comodidad* y *Seguridad* y menor que la media en *Precios*. En cambio, los años 2021, 2022 y 2023 se encuentran en la parte inferior, lo que sugiere un deterioro en la calidad de la experiencia, potencialmente relacionado con eventos no deseados como la pandemia o modificaciones en la infraestructura que afectaron negativamente la percepción de los usuarios.

El análisis de dispersión de los puntos en el gráfico permite identificar patrones de estabilidad y cambio en la satisfacción de los usuarios a lo largo del tiempo. Años consecutivos como 2016, 2017 y 2018 aparecen próximos entre sí, lo que indica una estabilidad en la percepción del servicio, sin cambios significativos ni en la eficiencia operativa ni en la calidad de la experiencia. En contraste, los años 2020 y 2024 se distancian considerablemente de los demás, sugiriendo la presencia de cambios

importantes en la gestión operativa y la percepción de los usuarios.

2.2 Análisis de Correspondencias Simples

2.2.1 Introducción

El Análisis Factorial de Correspondencias (AFC), también conocido como Análisis de Correspondencias Simples, es un método fundamental para describir una tabla de datos rectangular que contiene I filas y J columnas, cuando los datos provienen de un recuento obtenido mediante el cruce de dos variables cualitativas. Estas tablas, también denominadas tablas de contingencia, tablas de doble entrada o tablas cruzadas, se construyen a partir de la información obtenida al cruzar las modalidades o categorías de dos variables cualitativas definidas sobre un colectivo de n individuos.

La tabulación cruzada es especialmente útil para estudiar las relaciones existentes entre las variables y sus respectivas modalidades. El objetivo es determinar si las variables presentan diferencias significativas al compararse entre sí subgrupos de la muestra total.

El AFC ofrece varios beneficios al analizar datos cualitativos. Facilita la visualización de relaciones complejas entre modalidades, permitiendo representarlas gráficamente en un espacio reducido, lo que facilita su interpretación. También ayuda a identificar patrones ocultos y a reducir la complejidad de grandes tablas de contingencia, simplificando el análisis. En el ámbito de la investigación de mercados, mejora la toma de decisiones al ofrecer una visión clara de las preferencias de los consumidores.

2.2.2 Tabla de datos e hipótesis de independencia

En un AFC se analiza una tabla de contingencia compuesta por I modalidades de la variable X en filas y J modalidades de la variable Y en columnas. La frecuencia conjunta n_{ij} es el número de individuos en el colectivo (de tamaño n) que toman la modalidad i para X y la j para Y .

$X \backslash Y$	1	...	j	...	J	$n_{i\bullet}$
1	n_{11}	...	n_{1j}	...	n_{1J}	$n_{1\bullet}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
i	n_{i1}	...	n_{ij}	...	n_{iJ}	$n_{i\bullet}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
I	n_{I1}	...	n_{Ij}	...	n_{IJ}	$n_{I\bullet}$
$n_{\bullet j}$	$n_{\bullet 1}$	...	$n_{\bullet j}$	...	$n_{\bullet J}$	n

La tabla de frecuencias relativas se construye dividiendo cada elemento n_{ij} de la tabla de contingencia entre el total n , que representa la suma total de todas las celdas.

$X \backslash Y$	1	...	j	...	J	$n_{i\bullet}$
1	f_{11}	...	f_{1j}	...	f_{1J}	$f_{1\bullet}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
i	f_{i1}	...	f_{ij}	...	f_{iJ}	$f_{i\bullet}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
I	f_{I1}	...	f_{Ij}	...	f_{IJ}	$f_{I\bullet}$
$f_{\bullet j}$	$f_{\bullet 1}$	...	$f_{\bullet j}$	...	$f_{\bullet J}$	1

La frecuencia relativa de cada celda se calcula como:

$$f_{ij} = \frac{n_{ij}}{n}$$

donde f_{ij} representa una estimación de la probabilidad conjunta de i y j . A su vez, las frecuencias marginales ($f_{i\bullet}$, $f_{\bullet j}$) son la suma de las frecuencias para cada modalidad de una variable, sin considerar la otra variable. Estas permiten analizar la distribución marginal de cada variable independientemente del valor de la otra variable.

Hipótesis de independencia

En el contexto de una tabla de contingencia, la condición suficiente y necesaria de independencia se puede expresar matemáticamente como:

$$f_{ij} = f_{i\bullet} \cdot f_{\bullet j}, \quad \forall i, j$$

Cuando esta igualdad se cumple para todas las celdas o casillas de la tabla, podemos decir que las variables son independientes.

Si esta igualdad no se cumple, entonces las variables son dependientes y existe una relación entre ellas. En este caso, la frecuencia conjunta observada f_{ij} será diferente del producto de las frecuencias marginales $f_{i\bullet} \cdot f_{\bullet j}$.

1. Si $f_{ij} > f_{i\bullet} \cdot f_{\bullet j}$, las categorías i y j están más asociadas de lo que se esperaría bajo la hipótesis de independencia, lo que indica una atracción entre las categorías. Esto sugiere que cuando una categoría ocurre, es más probable que la otra también ocurra.
2. Si $f_{ij} < f_{i\bullet} \cdot f_{\bullet j}$, las categorías i y j están menos asociadas de lo que se esperaría bajo la hipótesis de independencia, lo que indica una repulsión entre las categorías. Esto sugiere que cuando una categoría ocurre, la otra es menos probable que ocurra.

La atracción o repulsión entre las categorías puede verse como un indicador de la existencia de una relación entre las variables. Cuando se da una atracción, se podría pensar que hay una relación más fuerte de lo esperado entre las categorías, mientras que en el caso de repulsión, las variables tienden a no ocurrir juntas tan a menudo como se esperaba. Este tipo de análisis es útil para entender la interacción entre variables y cómo se pueden influir mutuamente.

En una tabla de contingencia, la relación entre las filas y las columnas se caracteriza por una simetría que resulta clave para el análisis. En este contexto, dos filas se consideran similares o próximas si muestran patrones de asociación similares con respecto a las columnas. Esto ocurre si las filas están asociadas de manera parecida a las columnas, ya sea de forma excesiva o insuficiente, en comparación con lo que esperaríamos bajo la hipótesis de independencia. Este concepto se extiende a las columnas: dos columnas se consideran próximas si presentan asociaciones similares con las filas.

Este análisis da lugar a tipologías de filas que tienen una relación de proximidad entre sí, mientras que otras filas se oponen a las primeras. Es decir, algunos grupos de filas tienen un comportamiento similar en cuanto a su asociación con las columnas, mientras que otros se asocian de manera diferente. Lo mismo ocurre con las columnas, que pueden formar grupos con patrones de asociación similares respecto a las filas, pero también existen columnas que se oponen a otras en su relación con las filas.

La clave de este enfoque es la noción de semejanza, que permite estudiar la relación entre las dos variables X e Y , es decir, analizar hasta qué punto los datos observados se desvían de la situación de independencia. El propósito fundamental del AFC es descomponer esta relación en componentes simples, fáciles de interpretar, y medir la importancia relativa de cada uno de estos componentes. Este proceso de descomposición permite ordenar las tendencias y entender cuál de ellas tiene mayor relevancia en la estructura de la tabla.

2.2.3 Obtención de perfiles

En el análisis de correspondencias, no se trabaja directamente con la tabla original, sino que se transforma cada término de la tabla de manera que se facilite la interpretación de la relación entre las variables X e Y . La transformación clave consiste en dividir cada frecuencia observada f_{ij} por la frecuencia marginal de la fila $f_{i\bullet}$, obteniendo así lo que se denomina **perfil fila** i -ésimo ($\forall i = 1, \dots, I$).

Esta transformación permite estudiar la distribución de frecuencias de Y condicionada a la categoría i -ésima de X , lo que proporciona una visión más clara de cómo las categorías de una variable se relacionan con las categorías de la otra variable. La siguiente tabla ilustra el perfil fila i que indica cómo se distribuyen según los valores de Y los individuos de la categoría i -ésima de X .

$X \backslash Y$	1	$\dots$	j	$\dots$	J	
1			$\vdots$			
$\vdots$			$\vdots$			
i	$\frac{f_{i1}}{f_{i\bullet}}$	$\dots$	$\frac{f_{ij}}{f_{i\bullet}}$	$\dots$	$\frac{f_{iJ}}{f_{i\bullet}}$	1
$\vdots$			$\vdots$			
I			$\vdots$			
$f_{\bullet j}$	$f_{\bullet 1}$	$\dots$	$f_{\bullet j}$	$\dots$	$f_{\bullet J}$	1

El propósito de esta transformación es enfocar el análisis en la relación entre las dos variables a través de la desviación de los porcentajes dentro de cada fila. Al convertir las frecuencias en perfiles, se facilita la comparación entre las filas en términos relativos, eliminando el efecto del tamaño absoluto de las frecuencias.

Debido a la simetría de la tabla, se puede razonar de la misma manera para las columnas. En este caso se obtiene el **perfil columna** j -ésimo ($\forall j = 1, \dots, J$).

$X \backslash Y$	1	$\dots$	j	$\dots$	J	$f_{i\bullet}$
1			$\frac{f_{1j}}{f_{\bullet j}}$			$f_{1\bullet}$
$\vdots$			$\vdots$			$\vdots$
i	$\dots$	$\dots$	$\frac{f_{ij}}{f_{\bullet j}}$	$\dots$	$\dots$	$f_{i\bullet}$
$\vdots$			$\vdots$			$\vdots$
I			$\frac{f_{Ij}}{f_{\bullet j}}$			$f_{I\bullet}$
			1			1

2.2.4 Descripción de las nubes de perfiles

Existen dos nubes de puntos que representan las relaciones entre las modalidades de las variables X e Y .

Nube de perfiles fila

La nube de perfiles fila está constituida por I puntos en $\mathbb{R}^J$, cuyas coordenadas vienen dadas por:

$$\left(\frac{f_{i1}}{f_{i\bullet}}, \dots, \frac{f_{ij}}{f_{i\bullet}}, \dots, \frac{f_{iJ}}{f_{i\bullet}} \right)^t, \quad \text{para } i = 1, \dots, I$$

Cada perfil fila representa una modalidad de la variable X y tiene un peso igual a su marginal, $f_{i\bullet}$. El baricentro o centro de gravedad de los puntos que conforman la nube de perfiles fila es la distribución marginal de Y , $(f_{\bullet 1}, \dots, f_{\bullet j}, \dots, f_{\bullet J})^t$. Representa el perfil medio de las filas, es decir, el promedio ponderado de todos los perfiles fila considerando como pesos las frecuencias marginales de cada fila. La j -ésima coordenada de este baricentro se expresa como:

$$f_{\bullet j} = \sum_{i=1}^I f_{i\bullet} \cdot \frac{f_{ij}}{f_{i\bullet}} \quad \forall i, j$$

Nube de perfiles columna

De forma análoga, la nube de perfiles columna está constituida por J puntos en $\mathbb{R}^I$, cuyas coordenadas vienen dadas por:

$$\left(\frac{f_{1j}}{f_{\bullet j}}, \dots, \frac{f_{ij}}{f_{\bullet j}}, \dots, \frac{f_{Ij}}{f_{\bullet j}} \right)^t, \quad \text{para } j = 1, \dots, J$$

Cada perfil columna representa una modalidad de la variable Y y tiene un peso igual a su marginal $f_{\bullet j}$. El baricentro de la nube de perfiles columna es la distribución marginal de la variable X , $(f_{1\bullet}, \dots, f_{i\bullet}, \dots, f_{I\bullet})^t$, que representa el perfil medio de las columnas y se calcula como el promedio ponderado de los perfiles columna. La i -ésima coordenada de este baricentro se expresa como:

$$f_{i\bullet} = \sum_{j=1}^J f_{\bullet j} \cdot \frac{f_{ij}}{f_{\bullet j}} \quad \forall i, j$$

Si X e Y fuesen independientes todos los perfiles fila serían iguales a la distribución marginal de Y , $(f_{\bullet 1}, \dots, f_{\bullet j}, \dots, f_{\bullet J})^t$, y todos los perfiles columna a la marginal de X , $(f_{1\bullet}, \dots, f_{i\bullet}, \dots, f_{I\bullet})^t$.

2.2.5 Distancia χ^2 : semejanza entre perfiles

En un AFC, la distancia χ^2 mide cómo de diferentes son dos perfiles columna o dos perfiles fila.

La distancia χ^2 entre el perfil fila i y el perfil fila i' será:

$$d_{\chi^2}(i, i') = \sum_j \frac{1}{f_{\bullet j}} \left(\frac{f_{ij}}{f_{i\bullet}} - \frac{f_{i'j}}{f_{i'\bullet}} \right)^2$$

La distancia χ^2 es una forma de medir la diferencia entre dos filas en una tabla de contingencia, teniendo en cuenta la importancia relativa de cada categoría o modalidad de Y . En lugar de tratar todas las categorías por igual, esta distancia da más peso a las categorías que son menos comunes, es decir, menor $f_{\bullet j}$. Esto se hace multiplicando las diferencias al cuadrado por el inverso de la frecuencia marginal asociada a cada sumando.

Asímismo, la distancia χ^2 entre el perfil columna j y el perfil columna j' será:

$$d_{\chi^2}(j, j') = \sum_i \frac{1}{f_{i\bullet}} \left(\frac{f_{ij}}{f_{\bullet j}} - \frac{f_{ij'}}{f_{\bullet j'}} \right)^2$$

Una característica clave de la distancia χ^2 es su propiedad de equivalencia distribucional. Esto significa que si dos columnas (o filas) son muy similares (proporcionales) y se juntan en una sola, la distancia entre las filas (o columnas) no cambia. Esto hace que el análisis sea más estable y confiable, incluso cuando los datos no son perfectamente proporcionales. Por ejemplo, si se trabaja con datos sobre profesiones y regiones, y se agrupan regiones similares, los resultados del análisis no se verán significativamente afectados.

2.2.6 Ajuste de las nubes de perfiles

Tras haber descrito la estructura de las nubes de perfiles fila y columna, el siguiente paso consiste en realizar el ajuste de estas nubes para representarlas de forma más sencilla en un espacio de menor dimensión, manteniendo al mismo tiempo la mayor parte de la variabilidad y las distancias relativas entre los puntos.

El ajuste de la nube de perfiles fila en $\mathbb{R}^J$ busca obtener una representación más simple de la nube, tal que las distancias entre los puntos en la nube proyectada sean lo más similares posibles a las distancias en el espacio original.

La nube de perfiles fila proyectada será centrada, es decir, que su baricentro se ubicará en el origen de los ejes. La distancia χ^2 entre un perfil fila i y su centro de gravedad es:

$$d_{\chi^2}(i, G_I) = d_{\chi^2}(i) = \sum_j \frac{1}{f_{\bullet j}} \left(\frac{f_{ij}}{f_{i\bullet}} - f_{\bullet j} \right)^2$$

De manera similar, el ajuste de la nube de perfiles columna se plantea con los mismos objetivos. La nube de perfiles columna se proyecta sobre un espacio de menor dimensión que $\mathbb{R}^I$, buscando también preservar las distancias relativas entre los puntos y la variabilidad máxima a lo largo de los ejes seleccionados. Al igual que en las filas, se utiliza la distancia χ^2 para evaluar las diferencias entre los perfiles y su centro de gravedad, y cada perfil columna está ponderado por su frecuencia marginal $f_{j\bullet}$. La distancia χ^2 entre un perfil columna j y su centro de gravedad es:

$$d_{\chi^2}(j, G_J) = d_{\chi^2}(j) = \sum_i \frac{1}{f_{i\bullet}} \left(\frac{f_{ij}}{f_{\bullet j}} - f_{i\bullet} \right)^2$$

Ambas nubes, la de perfiles fila y la de perfiles columna, son dos formas complementarias de representar la misma información contenida en una tabla de contingencia. Dado que están estrechamente relacionadas, su análisis no es independiente, y esta relación se conoce como dualidad.

Gracias a esta simetría, se pueden establecer relaciones de transición que permiten la representación conjunta de perfiles fila y perfiles columna en un mismo espacio.

Inercia y su interpretación

La relación entre dos variables categóricas X e Y de una tabla de contingencia puede analizarse a través del estadístico z , que sigue aproximadamente una distribución χ^2 . Este estadístico permite contrastar la hipótesis de independencia, cuantificando la diferencia entre las frecuencias observadas y las esperadas si las variables fueran independientes. Su expresión es:

$$z = \sum_{i,j} \frac{(nf_{ij} - nf_{i\bullet}f_{\bullet j})^2}{nf_{i\bullet}f_{\bullet j}}$$

Este valor, salvo por el factor de escala n , coincide con la inercia total de la nube de perfiles fila en $\mathbb{R}^J$ o de la nube de perfiles columna en $\mathbb{R}^I$. La inercia mide la dispersión de los perfiles respecto a su centro de gravedad, por lo que refleja el grado de dependencia entre las dos variables. Por ejemplo, la inercia de la nube de perfiles fila se expresa de la siguiente manera:

$$I(i) = \sum_j f_{i\bullet} \sum_j \frac{1}{f_{\bullet j}} \left(\frac{f_{ij}}{f_{i\bullet}} - f_{\bullet j} \right)^2 = \sum_j f_{i\bullet} \cdot d_{\chi^2}(i, G_J)$$

Por lo que el estadístico z es igual a:

$$z = nI(i) = nI(j)$$

donde n es el tamaño muestral y $I(i)$, $I(j)$ son las inercias de las nubes de perfiles fila y columna respectivamente. Esta igualdad demuestra que la inercia total es idéntica en ambas nubes, reflejando la dualidad del análisis.

Cálculo de los ejes factoriales

Al igual que en un ACP, los resultados de un AFC se obtienen a partir de los valores y vectores propios obtenidos al diagonalizar una matriz (llamada matriz de inercia). Se cumple que:

$$I(i) = I(j) = \lambda_1 + \lambda_2 + \cdots + \lambda_{\min(I-1, J-1)}$$

donde $\lambda_1, \lambda_2, \dots, \lambda_{\min(I-1, J-1)}$ son los valores propios ordenados de mayor a menor. Todos ellos son positivos y menores que uno.

La dirección propia asociada al k -ésimo valor propio, λ_k , será el k -ésimo eje factorial. Las coordenadas o proyecciones de los perfiles fila, $\phi_k(i) \quad \forall i = 1, \dots, I$, y de los perfiles columna, $\psi_k(j) \quad \forall j = 1, \dots, J$, se calculan a partir de vectores propios asociados a λ_k . Estos ejes son ortogonales y forman planos principales.

La inercia proyectada sobre cada eje es igual al valor propio asociado:

$$\lambda_k = \sum_i f_{i\bullet} \cdot \phi_k^2(i) = \sum_j f_{\bullet j} \cdot \psi_k^2(j)$$

Además, los factores⁹ de mismo rango k en ambos espacios están relacionados mediante las siguientes **relaciones de transición**:

$$\phi_k(i) = \frac{1}{\sqrt{\lambda_k}} \sum_j \frac{f_{ij}}{f_{i\bullet}} \psi_k(j) \quad (3)$$

$$\psi_k(j) = \frac{1}{\sqrt{\lambda_k}} \sum_i \frac{f_{ij}}{f_{\bullet j}} \phi_k(i) \quad (4)$$

Estas relaciones justifican la representación simultánea de las filas y columnas sobre los planos factoriales:

- Según la expresión (3), la **posición de un perfil fila** i , $\phi_k(i)$, sobre un eje k se calcula como el baricentro de las posiciones de todas las columnas, ponderadas por la proporción, $\frac{f_{ij}}{f_{i\bullet}}$, que cada columna j representa en la fila i .
- Según la expresión (4), de forma análoga, la **posición de un perfil columna** j , $\psi_k(j)$, se obtiene como el baricentro de las posiciones de todas las filas, ponderadas por la proporción, $\frac{f_{ij}}{f_{\bullet j}}$, que cada fila i representa en la columna j .

Así, una fila estará más cerca de aquellas columnas con las que tiene una relación más fuerte, y más alejada de las que están menos asociadas con ella. Esta simetría se conoce a menudo como doble propiedad baricéntrica.

⁹Se denomina factor al conjunto de coordenadas o proyecciones de los puntos de una nube sobre uno de sus ejes factoriales.

2.2.7 Aplicación a la Encuesta de bienestar sobre enseñanza y asistencia sanitaria

Descripción de los datos

Para la realización y puesta en marcha del análisis se ha utilizado un conjunto de datos extraído de un estudio realizado por el Centro de Investigaciones Sociológicas (CIS) a finales de 2024, titulado “Actitudes hacia el Estado de Bienestar II”. El estudio recoge la percepción ciudadana sobre distintos servicios públicos en España mediante una encuesta realizada a 3857 personas. Los datos y la ficha técnica de esta encuesta fueron obtenidos de la página web principal del CIS Centro de Investigaciones Sociológicas (2024).

En concreto, se han extraído los datos de la siguiente *Pregunta 3* (P.3) del cuestionario:

“Por lo que Ud. sabe, ¿en qué medida diría que funcionan actualmente en España cada uno de los siguientes servicios públicos: Enseñanza, Asistencia sanitaria, Gestión de las pensiones, Administración de la justicia, Seguridad ciudadana, Servicios sociales, Transporte Público, Obras públicas y Ayuda a personas dependientes?”

Las posibles respuestas que los entrevistados podían seleccionar para cada servicio eran:

- 1 = Muy satisfactoriamente
- 2 = Bastante satisfactoriamente
- 3 = Poco satisfactoriamente
- 4 = Nada satisfactoriamente
- 8 = No sabe (N.S.)
- 9 = No contesta (N.C.)

De todas las variables incluidas en esta pregunta, se han seleccionado únicamente dos para este análisis: **Enseñanza** y **Asistencia sanitaria**, por considerarse servicios esenciales dentro del estudio.

Como **variable suplementaria**, y con el objetivo de enriquecer el análisis, se ha incorporado una tercera variable que recoge la percepción de cada individuo sobre si las administraciones públicas le proporcionan más, aproximadamente lo mismo o menos de lo que paga en impuestos y cotizaciones.

Esta información viene dada de la *Pregunta 6* (P.6) del cuestionario:

“Y más en concreto, teniendo en cuenta lo que Ud. y su familia reciben de las distintas administraciones públicas, ¿diría Ud. que las administraciones públicas le dan más de lo que Ud. paga en impuestos y cotizaciones, más o menos lo que paga, o menos de lo que paga en impuestos y cotizaciones?”

Las posibles respuestas eran:

- 1 = Más de lo que paga
- 2 = Más o menos lo que paga

- 3 = Menos de lo que paga
- 8 = No sabe (N.S.)
- 9 = No contesta (N.C.)

Previo al análisis, se ha llevado a cabo un proceso de limpieza y transformación de los datos. Se eliminaron las respuestas (“No sabe”, “No contesta”) y se realizó un recuento de las frecuencias de las $n = 3798$ respuestas restantes, con el fin de construir la tabla de contingencia a analizar.

Tabla 7: Tabla de contingencia entre la valoración de la Enseñanza y Asistencia Sanitaria.

	Sanidad1	Sanidad2	Sanidad3	Sanidad4	Más.paga	Igual.paga	Menos.paga
Enseñanza1	241	188	63	6	69	171	241
Enseñanza2	207	1177	546	64	213	637	1105
Enseñanza3	52	316	611	132	65	212	828
Enseñanza4	8	35	67	85	4	15	171

Las columnas ‘más.paga’, ‘igual.paga’ y ‘menos.paga’ corresponden a la variable suplementaria que recoge la percepción individual sobre el equilibrio entre lo pagado en impuestos y lo recibido por parte de las administraciones públicas.

Contraste de independencia

Como se ha comentado, la relación entre las dos variables, *Enseñanza* y *Sanidad*, puede analizarse a través de un estadístico z , que sigue aproximadamente una distribución χ^2 .

Tabla 8: Resultado del test Chi-cuadrado.

Estadístico	Valor	Grados de libertad	Valor p
z	1413.134	9	$2,2 \times 10^{-16}$

El valor del estadístico $z = 1413,134$ es muy alto en comparación con el valor crítico esperado para una distribución χ^2 con 9 grados de libertad a un nivel de significación del 5 % (valor crítico = 16,9). Por lo tanto, rechazamos la hipótesis nula de que las dos variables son independientes, es decir, están relacionadas y tiene sentido realizar un AFC de su tabla de contingencia.

Resultados del AFC: elección del número de factores

Del mismo modo que al hacer un ACP, para decidir cuántos factores interpretar se estudia la inercia proyectada en los ejes (valores propios).

Tabla 9: Valores propios y tasas de inercia proyectadas del AFC.

	Valores propios	Inercia proyectada (%)	Inercia acumulada (%)
dim 1	0.23	61.54	61.54
dim 2	0.10	28.04	89.58
dim 3	0.04	10.42	100.00

El primer factor recoge un 61,54 % de la inercia total, seguido del segundo que representa un 28,04 % adicional. Conjuntamente, recogen el 89,58 % de la inercia. Esto indica que los dos factores son suficientes para representar la mayor parte de la información contenida en los datos.

Para visualizarlo de manera más clara, a continuación se representan las tasas de inercia proyectadas sobre cada factor mediante un gráfico de código.




Figura 4: Porcentaje de inercia recogida por cada factor principal.

Perfiles fila: Enseñanza

Tabla 10: Coordenadas, contribuciones, cosenos cuadrados para los dos primeros factores (Dim. 1 y Dim. 2), distancia χ^2 al origen y frecuencias relativas marginales de los perfiles fila.

	Dim 1	Dim 2	Dim 1	Dim 2	Dim 1	Dim 2	Distancia	F.Marg
Enseñanza1	-0.898	0.549	46.147	37.830	0.722	0.270	1.056	0.131
Enseñanza2	-0.132	-0.243	4.008	29.649	0.202	0.680	0.294	0.525
Enseñanza3	0.465	0.048	27.614	0.659	0.787	0.009	0.524	0.293
Enseñanza4	0.996	0.805	22.230	31.862	0.509	0.333	1.395	0.051

En la Tabla 10 se observan las ayudas a la interpretación para los dos primeros factores principales junto con las distancias χ^2 al origen y las frecuencias relativas marginales para las cuatro modalidades de la variable X (Valoración del funcionamiento de la *Enseñanza*).

Las coordenadas de las modalidades permiten representarlas en el plano principal. Por ejemplo, las coordenadas de modalidad *Enseñanza 4* son 0.996 y 0.805 en el primer y segundo eje, respectivamente.

Cada eje se interpreta en función de las modalidades que más contribuyen a su formación (contribución alta) y que estén bien representadas en él (coseno cuadrado alto).

El primer eje contrapone la modalidad Muy satisfactoriamente (*Enseñanza 1*), proyectada en el lado negativo del eje, frente a Poco o Nada satisfactoriamente (*Enseñanza 3 y 4*), en el lado positivo

del eje.

El segundo eje añade la distinción entre modalidades más extremas (*Enseñanza 1 y 4*) frente a la intermedia (*Enseñanza 2 = Bastante Satisfactoriamente*).

Perfiles columna: Asistencia sanitaria

Tabla 11: Coordenadas, contribuciones, cosenos cuadrados para los dos primeros factores (Dim. 1 y Dim. 2), distancia χ^2 al origen y frecuencias relativas marginales de los perfiles columna.

	Dim 1	Dim 2	Dim 1	Dim 2	Dim 1	Dim 2	Dist.	F.Marg
Sanidad1	-0.870	0.554	44.251	39.373	0.706	0.286	1.036	0.134
Sanidad2	-0.174	-0.251	5.953	27.259	0.270	0.564	0.334	0.452
Sanidad3	0.361	-0.035	19.237	0.391	0.705	0.007	0.429	0.339
Sanidad4	0.962	0.675	30.560	32.977	0.605	0.298	1.237	0.076

En la Tabla 11 se muestran las ayudas a la interpretación para los dos primeros factores principales junto con las distancias χ^2 al origen y las frecuencias relativas marginales para las cuatro modalidades de la variable *Y* (Valoración del funcionamiento de la *Asistencia sanitaria*).

Se puede observar como los resultados de los perfiles columna son muy parecidos a los resultados de los perfiles fila.

Perfiles columna suplementarios

Tabla 12: Coordenadas, cosenos cuadrados y distancia χ^2 al origen de los perfiles columna suplementarios.

	Dim 1	Dim 2	Dim 1	Dim 2	Dist.
Más.paga	-0.333	-0.066	0.956	0.038	0.340
Igual.paga	-0.251	-0.115	0.815	0.171	0.278
Menos.paga	0.172	0.055	0.888	0.091	0.182

La Tabla 12 muestra las ayudas a la interpretación para los dos primeros factores principales junto con las distancias χ^2 al origen para las tres modalidades de la variable suplementaria (Percepción de servicios recibidos ante impuestos pagados).

Analizando los resultados de la variable suplementaria, se observa que aunque no contribuye a la construcción de los ejes factoriales (por lo que no hay contribuciones en la tabla anterior) proporciona información valiosa.

Las tres modalidades suplementarias están bien representadas en el primer eje, donde se contraponen los que piensan que reciben “Igual o Más” de lo que pagan en impuestos frente a los que piensan que reciben “Menos”. Estos últimos se asocian más a las modalidades activas Poco o Nada satisfactoriamente de los servicios de *Enseñanza y Asistencia sanitaria*.

Representación del plano principal

Todos estos comentarios aparecen reflejados en el siguiente plano principal donde se representan de forma simultánea los perfiles fila (*Enseñanza*) y perfiles columna (*Asistencia sanitaria*), junto con las modalidades suplementarias.




Figura 5: Plano principal del AFC

Se observa que las modalidades correspondientes a valoraciones similares de satisfacción se agrupan de manera cercana en el plano principal, lo que indica que existe un patrón en la percepción de la satisfacción respecto al funcionamiento de los dos servicios públicos analizados: *Enseñanza* y *Asistencia sanitaria*.

En el primer eje se contraponen las modalidades extremas mientras que en el segundo estas se contraponen a las intermedias. Como resultado, la nube de modalidades proyectada sobre el plano principal refleja aparentemente la forma de una parábola. Esto es algo que suele ocurrir en los resultados de un AFC y se denomina efecto Guttman.

2.3 Análisis de Correspondencias Múltiples

El Análisis (Factorial) de Correspondencias Múltiples es una generalización del AFC para estudiar las relaciones entre variables cualitativas (normalmente más de dos, que es lo que se hace en un AFC). Se aplica a tablas de datos que cruzan individuos en filas y variables cualitativas en columnas.

Sin embargo, es una de las técnicas más utilizadas en estudios cuantitativos de investigación de mercados que, a menudo, se basan en los datos de una encuesta con múltiples preguntas cerradas, cada una con un abanico de posibles respuestas mutuamente excluyentes (un individuo solo puede elegir una por variable). Cada pregunta sería una variable cualitativa y las posibles respuestas sus modalidades.

Para la explicación de esta técnica, se opta por presentar de forma conjunta la teoría y la práctica ya que el ACM está estrechamente vinculado con el AFC.

2.3.1 Descripción de los datos

Se utilizará de nuevo la *Pregunta 3* (P.3) del estudio realizado por el CIS donde se pide valorar el funcionamiento de 9 servicios públicos:

“Por lo que Ud. sabe, ¿en qué medida diría que funcionan actualmente en España cada uno de los siguientes servicios públicos: Enseñanza, Asistencia sanitaria, Gestión de las pensiones, Administración de la justicia, Seguridad ciudadana, Servicios sociales, Transporte Público, Obras públicas y Ayuda a personas dependientes”.

Las posibles repuestas para cada servicio son las siguientes:

- 1 = Muy satisfactoriamente
- 2 = Bastante satisfactoriamente
- 3 = Poco satisfactoriamente
- 4 = Nada satisfactoriamente

En este caso, hay nueve variables activas con cuatro modalidades cada una ($p_k = 4, \forall k = 1, \dots, s$). Por lo tanto, el total de modalidades activas será 36 ($p = \sum_{k=1}^s p_k = 36$). La tabla de datos analizada tiene $n = 3189$ filas (individuos) y $s = 9$ columnas (variables).

A partir de esta tabla, se construye la Tabla Disyuntiva Completa $\mathbf{Z}$ (TDC) que cruza los n individuos en filas y las p modalidades en columnas. La tabla $\mathbf{Z}$ puede expresarse como la concatenación horizontal de las matrices binarias de todas las variables.

$$\mathbf{Z} = [\mathbf{Z}_1, \dots, \mathbf{Z}_k, \dots, \mathbf{Z}_s]$$

Los elementos de esta tabla binaria son $z_{ij} = 1$, en el caso de que el individuo de la fila i posea la modalidad o categoría que figura en la columna j de la tabla, y $z_{ij} = 0$ en caso contrario. En general, esta tabla es de dimensiones $n \times p$. En nuestro caso, $\mathbf{Z}$ es una tabla de dimensiones: 3189×36 .

$$\mathbf{Z} = \begin{array}{c|cccc|ccc|c} & x_1^1 & x_2^1 & \cdots & x_{p_1}^1 & \cdots & x_1^s & x_2^s & \cdots & x_{p_s}^s & z_{i\bullet} \\ \hline 1 & 1 & 0 & \cdots & 0 & \cdots & 0 & 1 & \cdots & 0 & s \\ 2 & 0 & 1 & \cdots & 0 & \cdots & 1 & 0 & \cdots & 0 & s \\ \vdots & \vdots & \vdots & & \vdots & & \vdots & \vdots & & \vdots & \vdots \\ n & 0 & 0 & \cdots & 1 & \cdots & 0 & 0 & \cdots & 1 & s \\ \hline z_{\bullet j} & & & & & & & & & & ns \end{array}$$

Nota: La última fila ($z_{\bullet j}$) y columna ($z_{i\bullet}$) representan las sumas de todos los elementos de la columna j y fila i , respectivamente.

La suma de los elementos de cada fila i , es igual al número de variables estudiadas s , en nuestro caso 9. En cuanto a la marginal en términos relativos, $f_{i\bullet}$, es igual a $1/n$. En nuestro caso la frecuencia relativa marginal de cada fila i y el peso de cada individuo es $f_{i\bullet} = 1/3189 \quad \forall i = 1, \dots, n$.

La suma de los elementos de cada columna j es igual al número de individuos que toman la modalidad j . Se le llama efectivo de la modalidad y se denota como $z_{\bullet j}$. Como el total de la tabla $\mathbf{Z}$ es ns la frecuencia relativa marginal de cada columna j es igual a: $\frac{z_{\bullet j}}{ns}$. La frecuencia relativa marginal de cada columna es el peso de la modalidad j equivalente a los $f_{\bullet j}$ de la teoría del AFC.

2.3.2 Tabla de Burt

La tabla de Burt, B , se construye a partir de la matriz $\mathbf{Z}$ como:

$$B = \mathbf{Z}^t \mathbf{Z}$$

El resultado es una tabla simétrica en la que cada elemento ($b_{jj'}$) indica¹⁰ el número de individuos que han elegido de forma conjunta las modalidades j y j' , donde:

$$b_{jj'} = \sum_{i=1}^n z_{ij} \cdot z_{ij'}$$

Los bloques diagonales de la tabla de Burt corresponden a la tabla de contingencia de una variable consigo misma, es decir, cruzan las categorías de la misma variable.

Los bloques no diagonales son tablas de contingencia que resultan de cruzar las respuestas de dos variables diferentes, mostrando cómo se relacionan las categorías entre variables distintas.

2.3.3 Distancia χ^2 : semejanza entre perfiles

Desde el punto de vista de los cálculos, el ACM se basa en un Análisis Factorial de Correspondencias Simples aplicado a la Tabla Disyuntiva Completa. Se trabaja con los perfiles fila y perfiles columna de la tabla $\mathbf{Z}$. La distancia χ^2 entre dos perfiles fila i y i' es:

¹⁰La notación j' se emplea para distinguir entre dos modalidades distintas dentro del conjunto total de modalidades.

$$d_{\chi^2}(i, i') = \frac{n}{s} \sum_{j=1}^p \frac{(z_{ij} - z_{i'j})^2}{z_{\bullet j}}$$

Interpretando esta distancia, dos individuos estarán cercanos si escogen las mismas modalidades. Al contrario, dos individuos estarán más alejados cuantas menos modalidades en común hayan elegido.

Y la distancia χ^2 entre dos perfiles columna j y j' es:

$$d_{\chi^2}(j, j') = \sum_{i=1}^n n \left(\frac{z_{ij}}{z_{\bullet j}} - \frac{z_{ij'}}{z_{\bullet j'}} \right)^2$$

En este caso, dos modalidades estarán próximas si han sido escogidas por los mismos individuos.

2.3.4 Descripción de las nubes de perfiles fila (individuos) y perfiles columna (modalidades)

La información contenida en los datos puede visualizarse como una nube de perfiles fila (formada por n puntos individuo en p dimensiones) o una nube de perfiles columna (con p puntos o modalidades en n dimensiones).

Cada perfil fila (individuo i) tiene un peso igual a $\frac{1}{n}$ y cada perfil columna (modalidad j) un peso igual a: $\frac{z_{\bullet j}}{ns}$.

La inercia total de ambas nubes es la misma y es igual a $\frac{p}{s} - 1$. Por tanto, depende del número de modalidades (p) y de variables (s) pero no de la relación que haya entre ellas.

El objetivo es encontrar los ejes principales (ortogonales entre sí) sobre los cuales se maximice la inercia de las proyecciones de los puntos fila (estas se denotarán como $\phi_\alpha(i) \quad \forall i = 1, \dots, n$) y columna ($\psi_\alpha(j) \quad \forall j = 1, \dots, p$). De forma que los planos principales recojan el máximo posible de información y esta pueda interpretarse en función de coordenadas o proyecciones de los individuos y modalidades que más contribuyen a la formación de los ejes y estén bien representadas en los mismos.

2.3.5 Valores propios y tasas de inercia proyectadas

Cada eje principal α ($\alpha = 1, 2, \dots, p - s$) es una dirección propia de la llamada matriz de inercia. El valor propio, λ_α , asociado a cada eje coincide con la inercia proyectada sobre el mismo. Todos los valores propios son mayores a uno y se consideran relevantes aquellos mayores que $\frac{1}{s}$.

En una Tabla Disyuntiva Completa **Z** las columnas de las modalidades de cada variable son ortogonales entre sí, hay una ortogonalidad artificial entre ellas. Debido a esto, los valores propios que se obtienen en el ACM dan una idea muy pesimista de la información que refleja cada eje principal. Por ello, Benzécri, en 1979, propuso una corrección para obtener una tasa de inercia proyectada más comparable, en términos de representación de los ejes, con las técnicas anteriormente estudiadas.

$$\lambda_{\alpha}^* = \left(\frac{s}{s-1} \right)^2 \left(\lambda_{\alpha} - \frac{1}{s} \right)^2, \quad \forall \lambda_{\alpha} > \frac{1}{s}.$$

donde:

- λ_{α}^* es el valor propio corregido.
- λ_{α} es el valor propio original obtenido del ACM.

Se calcula a continuación la inercia proyectada original y corregida en los ejes ($\alpha = 1, 2, \dots, p-s = 27$) a partir de la corrección de Benzécri.

Tabla 13: Valores propios del ACM, tasas de inercia proyectadas originales y corregidas.

	V.Propios	In.Proy (%)	In.Acum (%)	V.Prop.C	In.Proy.C (%)	In.Acum.C (%)
dim 1	0.42	14.12	14.12	0.13	65.54	65.54
dim 2	0.32	10.58	24.70	0.55	28.12	93.65
dim 3	0.21	6.91	31.60	0.12	6.30	99.95
dim 4	0.12	4.01	35.61	0.00	0.05	100.00
dim 5	0.11	3.76	39.37	0.00	0.00	100.00
dim 6	0.11	3.64	43.01	0.00	0.00	100.00
dim 7	0.10	3.45	46.46	0.00	0.00	100.00
dim 8	0.10	3.35	49.81	0.00	0.00	100.00
dim 9	0.10	3.33	53.14	0.00	0.00	100.00
dim 10	0.10	3.23	56.37	0.00	0.00	100.00
dim 11	0.10	3.20	59.57	0.00	0.00	100.00
dim 12	0.09	3.05	62.62	0.00	0.00	100.00
dim 13	0.09	2.99	65.61	0.00	0.00	100.00
dim 14	0.09	2.95	68.57	0.00	0.00	100.00
dim 15	0.09	2.89	71.46	0.00	0.00	100.00
dim 16	0.08	2.77	74.23	0.00	0.00	100.00
dim 17	0.08	2.73	76.97	0.00	0.00	100.00
dim 18	0.08	2.72	79.69	0.00	0.00	100.00
dim 19	0.08	2.68	82.37	0.00	0.00	100.00
dim 20	0.08	2.59	84.96	0.00	0.00	100.00
dim 21	0.07	2.45	87.41	0.00	0.00	100.00
dim 22	0.07	2.37	89.78	0.00	0.00	100.00
dim 23	0.07	2.36	92.14	0.00	0.00	100.00
dim 24	0.06	2.15	94.29	0.00	0.00	100.00
dim 25	0.06	2.10	96.39	0.00	0.00	100.00
dim 26	0.06	1.85	98.24	0.00	0.00	100.00
dim 27	0.05	1.76	100.00	0.00	0.00	100.00

Nota: Las tres últimas columnas muestran los valores corregidos a partir de la corrección de Benzécri.

Analizando los valores de las dos últimas columnas, se observa que los dos primeros factores recogen un 93,65 % de la inercia total, es decir, el plano principal recoge prácticamente toda la información contenida en los datos.

2.3.6 Plano principal de nube de modalidades activas

En el siguiente plano principal se representan simultáneamente las 36 modalidades de las 9 variables activas analizadas.




Figura 6: Plano principal de la nube de modalidades activas

Los porcentajes de inercia proyectada que aparecen en la Figura 6 son valores sin corregir.

2.3.7 Interpretación de los dos primeros factores principales

Tabla 14: Coordenadas, contribuciones y cosenos cuadrados para los dos primeros factores de las modalidades activas en el ACM.

	Dim 1	Dim 2	Dim 1	Dim 2	Dim 1	Dim 2
Educ_1	-1.228	1.341	4.776	7.604	0.207	0.247
Educ_2	-0.258	-0.406	0.923	3.068	0.075	0.187
Educ_3	0.656	-0.019	3.407	0.004	0.186	0.000
Educ_4	1.849	1.262	4.219	2.621	0.169	0.079
Sanidad_1	-1.093	1.168	3.970	6.055	0.173	0.198
Sanidad_2	-0.314	-0.371	1.180	2.194	0.083	0.115
Sanidad_3	0.454	-0.189	1.849	0.428	0.107	0.019
Sanidad_4	1.684	1.144	5.575	3.431	0.230	0.106
Pensiones_1	-1.086	0.958	3.917	4.073	0.171	0.133
Pensiones_2	-0.250	-0.408	0.751	2.674	0.053	0.141
Pensiones_3	0.387	-0.056	1.241	0.035	0.069	0.001
Pensiones_4	1.312	0.843	4.473	2.467	0.189	0.078
Justicia_1	-1.612	2.520	1.859	6.065	0.073	0.178
Justicia_2	-0.666	-0.072	2.796	0.044	0.140	0.002
Justicia_3	0.017	-0.291	0.004	1.593	0.000	0.098
Justicia_4	0.993	0.534	5.076	1.957	0.241	0.070
Seguridad_1	-1.057	1.103	3.365	4.892	0.145	0.158
Seguridad_2	-0.272	-0.364	0.947	2.268	0.070	0.126
Seguridad_3	0.429	-0.098	1.527	0.106	0.085	0.004
Seguridad_4	1.461	1.014	4.530	2.914	0.188	0.091
ServSoc_1	-1.382	1.979	3.220	8.811	0.131	0.269
ServSoc_2	-0.499	-0.273	2.666	1.067	0.172	0.052
ServSoc_3	0.352	-0.226	1.478	0.815	0.103	0.043
ServSoc_4	1.846	1.217	6.422	3.723	0.264	0.115
Transp_1	-0.840	1.097	2.662	6.049	0.118	0.202
Transp_2	-0.200	-0.376	0.520	2.451	0.039	0.139
Transp_3	0.430	-0.103	1.472	0.112	0.081	0.005
Transp_4	1.548	1.036	3.627	2.169	0.147	0.066
Obras_1	-1.170	1.450	3.096	6.347	0.129	0.198
Obras_2	-0.386	-0.317	1.700	1.534	0.115	0.078
Obras_3	0.352	-0.191	1.265	0.495	0.079	0.023
Obras_4	1.480	0.980	5.117	2.995	0.214	0.094
Depend_1	-1.288	1.841	2.062	5.618	0.082	0.168
Depend_2	-0.622	-0.072	2.591	0.047	0.133	0.002
Depend_3	0.087	-0.273	0.111	1.461	0.010	0.095
Depend_4	1.248	0.614	5.604	1.812	0.248	0.060

En la Tabla 14 se pueden observar las ayudas a la interpretación de las modalidades activas en los dos primeros factores principales.

En el ACM, las coordenadas nos permiten representar las modalidades en el plano principal. A

su vez, cada eje se interpreta en función de las modalidades que más contribuyen a su formación (contribución alta) y que estén bien representadas en el (coseno cuadrado alto).

Los resultados son muy parecidos a los del AFC. El primer eje contraponen las modalidades que valoran Muy satisfactoriamente el funcionamiento de los servicios públicos frente a las modalidades que lo valoran Poco o Nada satisfactoriamente. Estas modalidades tienen una contribución alta en la formación de este eje. Además, en líneas generales, son las modalidades que mejor representadas están.

Por otro lado, el segundo eje diferencia de forma clara las modalidades más extremas (Muy y Nada satisfactoriamente), frente a las modalidades intermedias (Bastante y Poco satisfactoriamente). Analizando los resultados, las modalidades que más contribuyen a la formación del segundo eje y que mejor están representadas son las modalidades extremas.

2.3.8 Relaciones baricéntricas

Entre las proyecciones de los individuos ($\phi_\alpha(i) \quad \forall i = 1, \dots, n$) y modalidades ($\psi_\alpha(j) \quad \forall j = 1, \dots, p$) sobre un eje cualquiera α existen las siguientes relaciones de transición:

$$\psi_\alpha(j) = \frac{1}{\sqrt{\lambda_\alpha}} \sum_{i=1}^n \frac{z_{ij}}{z_{\bullet j}} \phi_\alpha(i) \quad (5)$$

$$\phi_\alpha(i) = \frac{1}{\sqrt{\lambda_\alpha}} \sum_{j=1}^p \frac{z_{ij}}{z_{i\bullet}} \psi_\alpha(j) \quad (6)$$

El valor λ_α es el valor propio asociado a la dimensión α . Según la expresión (5), una modalidad j se proyecta sobre un eje α en el punto medio de las proyecciones de los individuos que la hayan escogido (salvo el factor de dilatación sobre el eje α , $\frac{1}{\sqrt{\lambda_\alpha}}$).

2.3.9 Variables suplementarias

Una vez analizada la tabla de datos activa, se van a describir las variables suplementarias utilizadas para enriquecer los resultados del análisis. Siguiendo con el estudio realizado por el CIS, se ha decidido incluir las *Preguntas 4 y 6*. La *Pregunta 4* (P.4) es:

“ Dígame, si cree Ud. que en el futuro cada uno de los siguientes aspectos de la protección social en España mejorará, seguirá igual o empeorará: Atención sanitaria, Cuidado de personas mayores, Sistema público de pensiones, Protección frente al desempleo, Acceso a la primera vivienda y Sistema educativo público. ”

Las posibles respuestas que los entrevistados podían seleccionar para cada uno de los seis servicios eran:

- 1 = Mejorará
- 2 = Seguirá igual
- 3 = Empeorará

- 8 = No sabe (N.S.)
- 9 = No contesta (N.C.)

La *Pregunta 6* (P.6), es la misma que se ha utilizado en el AFC:

“Y más en concreto, teniendo en cuenta lo que Ud. y su familia reciben de las distintas administraciones públicas, ¿diría Ud. que las administraciones públicas le dan más de lo que Ud. paga en impuestos y cotizaciones, más o menos lo que paga, o menos de lo que paga en impuestos y cotizaciones?”

Las posibles respuestas eran:

- 1 = Más de lo que paga
- 2 = Más o menos lo que paga
- 3 = Menos de lo que paga
- 8 = No sabe (N.S.)
- 9 = No contesta (N.C.)

Se han eliminado las respuestas “No sabe” y “No contesta”.

Para complementar más el análisis, se ha decidido incluir el rango de edad de las personas entrevistadas. Esta variable tiene 4 modalidades.

- 18–35 años
- 35–50 años
- 50–65 años
- 65–90 años

De esta manera, se consideran 8 variables suplementarias con un total de 25 modalidades que permitirán sacar conclusiones adicionales en el análisis. Sus coordenadas, cosenos cuadrados y valores test aparecen en la Tabla 15. Los valores test informan si una modalidad tiene una posición “significativa” sobre un eje. Generalmente, se considera significativa si $|V\text{-test}| > 1,96$ (aproximadamente 2).

Tabla 15: Coordenadas, Cosenos cuadrados y V-tests para los dos primeros factores de las modalidades suplementarias en el ACM.

	Dim 1	Dim 2	Dim 1	Dim 2	Dim 1	Dim 2
F_Sanidad_1	-0.398	0.109	0.037	0.003	-10.799	2.960
F_Sanidad_2	-0.267	-0.071	0.034	0.002	-10.398	-2.766
F_Sanidad_3	0.328	0.005	0.103	0.000	18.154	0.275
F_CMayores_1	-0.411	0.113	0.061	0.005	-13.893	3.833
F_CMayores_2	-0.152	-0.127	0.011	0.008	-5.911	-4.938
F_CMayores_3	0.379	0.026	0.102	0.000	18.031	1.250
F_Pensiones_1	-0.487	0.178	0.032	0.004	-10.168	3.708
F_Pensiones_2	-0.245	-0.037	0.020	0.000	-7.930	-1.195
F_Pensiones_3	0.188	-0.019	0.061	0.001	13.954	-1.431
F_Parados_1	-0.380	0.108	0.034	0.003	-10.347	2.938
F_Parados_2	-0.199	-0.126	0.026	0.010	-9.065	-5.751
F_Parados_3	0.361	0.071	0.093	0.004	17.198	3.372
F_Vivienda_1	-0.459	0.120	0.033	0.002	-10.267	2.681
F_Vivienda_2	-0.206	-0.064	0.012	0.001	-6.247	-1.948
F_Vivienda_3	0.169	-0.003	0.051	0.000	12.751	-0.219
F_Educ_1	-0.443	0.089	0.056	0.002	-13.329	2.677
F_Educ_2	-0.150	-0.120	0.015	0.009	-6.871	-5.501
F_Educ_3	0.414	0.074	0.105	0.003	18.320	3.256
(35,50]	0.062	0.039	0.002	0.001	2.278	1.437
(50,65]	0.069	-0.035	0.002	0.001	2.711	-1.365
(65,96]	-0.107	-0.112	0.002	0.003	-2.682	-2.824
[18,35]	-0.109	0.085	0.003	0.002	-3.204	2.513
P6_1	-0.516	0.009	0.028	0.000	-9.396	0.162
P6_2	-0.416	-0.106	0.067	0.004	-14.587	-3.722
P6_3	0.262	0.046	0.116	0.004	19.198	3.354




Figura 7: Modalidades suplementarias proyectadas sobre el plano principal del ACM

En la Figura 7, se representan las 25 modalidades suplementarias en el plano principal del ACM realizado.

Analizando los resultados de la *Pregunta 4* en la Tabla 15, se observa que en el primer eje existe una diferenciación clara entre los que piensan que en el futuro los servicios públicos “Mejorarán” y “Seguirán igual” frente a los que piensan que “Empeorarán”. Estos últimos se asocian más con los que no están nada satisfechos con el funcionamiento de los servicios públicos en la actualidad.

De acuerdo con los resultados de la *Pregunta 6*, al igual que en el AFC, se contraponen los que piensan que reciben “igual o más” de lo que pagan de impuestos frente a los que piensan que reciben “menos”. Estos últimos se asocian más con los que están poco o nada satisfechos con el funcionamiento de los servicios públicos en la actualidad.

En cuanto a los resultados del rango de edad, se observa que los valores test (aún siendo superiores a 2 en valor absoluto) son sensiblemente menores que los del resto de modalidades suplementarias. Por ello, la interpretación de sus posiciones debe tomarse con más cautela. Las personas de entre 35-50 y 50-65 años se relacionan más con los que están poco o nada satisfechos con el funcionamiento de los servicios públicos en la actualidad. Por el contrario, las personas de entre 18-35 y 65-95 años tienen una relación más estrecha con los que están bastante o muy satisfechos con los servicios públicos.

3 Conclusiones

En este Trabajo Fin de Grado se ha estudiado y, posteriormente, puesto en práctica diferentes técnicas de análisis de datos a través de conjuntos de datos reales, con el fin de poner de manifiesto su utilidad en un mundo cada vez más analítico. Se ha demostrado como el Análisis de Componentes Principales (ACP), el Análisis de Correspondencias Simples (AFC) y el Análisis de Correspondencias Múltiples (ACM) son capaces de ayudar a interpretar de manera más clara grandes conjuntos de datos, minimizando la pérdida de información.

El objetivo de este trabajo está lejos de ser una descripción teórica de las técnicas.

En primer lugar, dada la rapidez con la que evoluciona el campo del análisis de datos, se destaca la necesidad de las empresas de digitalizarse y adaptarse a entornos cada vez más orientados a la información. Es por ello que, progresivamente, las decisiones empresariales se volverán más precisas.

A continuación, se ha comprobado como cada una de las técnicas analizadas son valiosas para identificar patrones en los datos y facilitar su interpretación. El ACP permite estudiar relaciones entre variables cuantitativas, mientras que, el AFC y ACM relaciones entre variables cualitativas, las cuales son cada vez más abundantes dado el aumento de datos no estructurados.

Este trabajo está originalmente orientado a un contexto empresarial, con el objetivo de demostrar cómo estas técnicas pueden servir de apoyo en la toma de decisiones dentro de una organización. Sin embargo, dada la dificultad de encontrar conjuntos de datos reales de empresas, el análisis ha sido más genérico. Para el ACP se han utilizado datos de la Encuesta de Satisfacción realizada por el Metro Bilbao sobre el funcionamiento del transporte en tren. En cuanto al AFC y ACM, se han empleado datos pertenecientes de la Encuesta de actitudes hacia el Estado de Bienestar realizada por el CIS, con el fin de analizar la valoración del funcionamiento de los servicios públicos en España. Aún así, cada una de estas técnicas son igual de eficaces y aplicables a contextos empresariales, ya sea para analizar datos de clientes, procesos, inventario, etc.

Como una propuesta para trabajos futuros, se pueden implementar estas técnicas estadísticas a conjuntos de datos de empresas reales, con la finalidad de demostrar su utilidad en condiciones específicas.

En definitiva, el análisis de datos no es una opción para las organizaciones. Solo aquellas que consigan transformar los datos en conocimiento serán capaces de liderar mercados cada vez más dinámicos y con mayor competencia.

Bibliografía

- Cámara de Tecnologías de Información y Comunicación. (2018). *Casi 30 % de los datos generados serán en tiempo real para 2025*. <https://www.camtic.org/actualidad-tic/casi-30-de-los-datos-generados-seran-en-tiempo-real-para-2025/>
- Centro de Investigaciones Sociológicas. (2024). *Estudio 3487: Actitudes hacia el estado de bienestar (II)*. CIS. <https://www.cis.es/es/detalle-ficha-estudio?codEstudio=3487&origen=estudio>
- Fernández, K. & Modroño, J. I. (s.f.). *Estadística exploratoria multivariante: Teoría y aplicaciones en investigación de mercados*. Facultad de Ciencias Económicas y Empresariales, Departamento de Economía Aplicada III.
- Framework, B. D. (2024). *A short history of Big Data*. <https://www.bigdataframework.org/short-history-of-big-data/>
- Hasham, A. (2023). *It's time for a new interconnection model for the growing amount of data in motion*. Ciena. <https://www.ciena.com/insights/articles/2023/its-time-for-a-new-interconnection-model-for-the-growing-amount-of-data-in-motion/>
- Husson, F., Le, S. & Pagès, J. (2013). *Análisis de datos con R*. Escuela Colombiana de Ingeniería Julio Garavito.
- Jangam, R. (2023). *The power of data analytics: A case study of Netflix*. Medium. <https://medium.com/@raj.w.2336/the-power-of-data-analytics-a-case-study-of-netflix-555ae819b0d7>
- Jiménez, R. (2025). *¿Cuánta info guarda tu cerebro? Spoiler: Más que google drive*. El Comercio. <https://www.elcomercio.com/tendencias/salud/cerebro-humano-enfermedades-investigacion/>
- Kumar, N. (2024). *Big data statistics 2025: Growth and market data*. DemandSage. <https://www.demandpage.com/big-data-statistics/>
- Naeem, T. (2024). *Understanding structured, semi-structured, and unstructured data*. Astera. <https://www.astera.com/type/blog/structured-semi-structured-and-unstructured-data/>
- Posit Software. (2025). *RStudio: Integrated development environment for R and Python*. <https://posit.co/download/rstudio-desktop/>
- R Team. (2025). *R: The R project for statistical computing*. <https://www.r-project.org/>
- Rodríguez, S. (2018). *House of Cards: El éxito que Netflix creó gracias a la inteligencia artificial*. AI Talks. <https://aitalks.es/house-of-cards-el-exito-que-netflix-creo-gracias-a-la-inteligencia-artificial/>
- Rodríguez, S. (2022). *El 80 % de los datos que manejan las empresas son desestructurados*. Big Data Magazine. <https://bigdatamagazine.es/el-80-de-los-datos-que-manejan-las-empresas-son-desestructurados/>
- Seoane, A. (2025). *To be in B2B: Retos, tendencias y oportunidades del B2B en España*. Charla impartida en Fabrika, San Sebastián.
- Winn, J. (2024). *ETL vs ELT: Comprender las diferencias y elegir bien*. DataCamp. <https://www.datacamp.com/es/blog/etl-vs-elt>

Anexo

En este anexo se incluye el código utilizado en RStudio en la parte práctica del trabajo, ordenado por las tres técnicas utilizadas.

1. ACP de la Encuesta de calidad del Metro Bilbao

1.1. Carga de paquetes estadísticos

```
library(FactoMineR)
library(readxl)
library(dplyr)
library(corrplot)
library(knitr)
library(kableExtra)
```

1.2. Carga de datos

```
calidad <- read.table("C:/Users/Ibai/Downloads/MetroBilbaoCalidad_nombreCorto (1).csv",
                     header = TRUE,
                     sep = ";",
                     dec = ".",
                     fileEncoding = "latin1",
                     row.names = 1
                     )

activas <- c(1,3,4,6,9,12,13,16)

suplementarias <- c(10,11,17,18,20:22)

metro <- calidad[,c(activas, suplementarias)]

metro <- metro[rev(1:nrow(metro)), ]

metro1 <- metro
```

1.3. Cálculo de estadísticos principales

```
estadisticas <- data.frame(
  Recuento = sapply(metro, length),
  Media = sapply(metro, mean, na.rm = TRUE),
  Desv_Típ = sapply(metro, sd, na.rm = TRUE),
  CV = sapply(metro, function(x) sd(x, na.rm = TRUE) / mean(x, na.rm = TRUE)),
  Mín = sapply(metro, min, na.rm = TRUE),
  Máx = sapply(metro, max, na.rm = TRUE)
```

```
)
```

1.4. ACP y cálculo de la matriz de correlación

```
res.pca <- PCA(metro, quanti.sup = 9:15, graph = FALSE)
matriz <- round(cor(metro1[, 1:8]), 2)
matriz
barplot(res.pca$eig[, 1])
```

1.5. Cálculo de los valores propios

```
inercia <- res.pca$eig
inercia
```

1.6. Plano principal de la nube de variables activas y ayudas a la interpretación

```
plot.PCA(res.pca, choix = "var", title = "")

variables <- round(cbind(
  Coordinadas = res.pca$var$coord[, 1:2],
  Contribuciones = res.pca$var$contrib[, 1:2],
  Cos2 = res.pca$var$cos2[, 1:2]
), 2)

variables
```

1.7. Plano principal de la nube de individuos y ayudas a la interpretación

```
plot.PCA(res.pca, invisible="quali", title = "")

individuo <- round(cbind(
  Coordinadas = res.pca$ind$coord[, 1:2],
  Contribuciones = res.pca$ind$contrib[, 1:2],
  Cos2 = res.pca$ind$cos2[, 1:2]
), 2)

individuo
```

2. AFC de la Encuesta de bienestar sobre enseñanza y asistencia sanitaria

2.1. Carga de paquetes estadísticos

```
library(FactoMineR)
library(factoextra)
library(knitr)
library(kableExtra)
```

2.2. Carga de datos

```
servicios <- read.table("C:/Users/Ibai/Downloads/servicios12.csv",
                        header = TRUE,
                        sep = ";",
                        dec = ".",
                        fileEncoding = "latin1",
                        row.names = 1
)
```

2.3. Contraste de independencia

```
servicios3 <- servicios[1:4, 1:4]
test <- chisq.test(servicios3, correct = FALSE)

chi2 <- as.numeric(test$statistic)
df <- as.numeric(test$parameter)
p <- test$p.value
```

2.4. AFC y cálculo de los valores propios

```
res.ca <- CA(servicios, col.sup= 5:7, graph = FALSE)
inercia <- res.ca$eig
inercia
barplot(res.ca$eig[,1])
```

2.5. Cálculo de las ayudas a la interpretación para los perfiles fila (Enseñanza) en los dos primeros factores, distancia χ^2 al origen y frecuencias relativas

```
distancias <- apply(res.ca$row$coord, 1, function(x) sqrt(sum(x^2)))

fi <- res.ca$call$marge.row

cccrow <- round(cbind(
```

```

Coordenadas = res.ca$row$coord[, 1:2],
Contribuciones = res.ca$row$contrib[, 1:2],
Cos2 = res.ca$row$cos2[, 1:2],
Distancia = distancias,
F.Marg = fi
), 3)

cccrow

```

2.6. Cálculo de las ayudas a la interpretación para los perfiles columna (Asistencia sanitaria) en los dos primeros factores, distancia χ^2 al origen y frecuencias relativas

```

distancias2 <- apply(res.ca$col$coord, 1, function(x) sqrt(sum(x^2)))

fj <- res.ca$call$marge.col

cccol <- round(cbind(Coordenadas = res.ca$col$coord[, 1:2],
  Contribuciones = res.ca$col$contrib[, 1:2],
  Cos2 = res.ca$col$cos2[, 1:2],
  Dist. = distancias2,
  F.Marg = fj
), 3)

cccol

```

2.7. Cálculo de las ayudas a la interpretación para los perfiles columna suplementarios en los dos primeros factores y distancia χ^2 al origen

```

distancias3 <- apply(res.ca$col.sup$coord, 1, function(x) sqrt(sum(x^2)))

colsuplementaria <- round(cbind(Coordenadas = res.ca$col.sup$coord[, 1:2],
  Cos2 = res.ca$col.sup$cos2[, 1:2],
  Dist. = distancias3
), 3)

colsuplementaria

```

2.8. Representación del plano principal

```

res.ca <- CA(servicios, col.sup= 5:7)

```

3. ACM de la encuesta de bienestar sobre servicios públicos en España

3.1. Carga de paquetes estadísticos

```
library(FactoMineR)
library(factoextra)
library(knitr)
library(kableExtra)
library(dplyr)
```

3.2. Carga de datos

```
bienestar2 <- read.table("C:/Users/Ibai/Downloads/bienestar_CIS_2024.csv",
                        header = TRUE,
                        sep = ";",
                        dec = ".",
                        fileEncoding = "latin1",
                        row.names = 1
)

bienestar2[] <- lapply(bienestar2, as.factor)
```

3.3. ACM y cálculo de los valores propios (corrección de Benzécri)

```
res.mca <- MCA(bienestar2, quali.sup = 10:17, graph = FALSE)

eig <- as.data.frame(res.mca$eig)

#Para el cálculo de la corrección de Benzécri se utilizó Excel.

eig$valor_corregido <- c(0.129, 0.552, 0.124, 0.001, 0.000, 0.000, rep(NA, 21))
eig$porcentaje_corregido <- c(65.538, 28.118, 6.302, 0.051, 0.001, 0.001, rep(NA, 21))
eig$acumulada_corregido <- c(65.538, 93.646, 99.947, 99.998, 99.999, 100.000, rep(NA, 21))
```

3.4. Cálculo de las ayudas a la interpretación de las modalidades activas para los dos primeros factores

```
variables <- round(cbind(
  Coordinadas = res.mca$var$coord[, 1:2],
  Contribuciones = res.mca$var$contrib[, 1:2],
  Cos2 = res.mca$var$cos2[, 1:2]
), 3)

variables
```

3.5. Representación del plano principal de modalidades activas

```
fviz_mca_var(res.mca,
             repel = TRUE,
             invisible = "quali.sup",
             ggtheme = theme_minimal(),
             title = "")
```

3.6. Cálculo de las ayudas a la interpretación de las modalidades suplementarias para los dos primeros factores

```
suplementarias <- round(cbind(
  Coordinadas = res.mca$quali.sup$coord[, 1:2],
  Cos2 = res.mca$quali.sup$cos2[, 1:2],
  Test = res.mca$quali.sup$v.test[, 1:2]
), 3)

suplementarias
```

3.7. Representación del plano principal de modalidades suplementarias

```
plot(res.mca, invisible = c("ind", "var"))
```